CONFIDENTIAL EXTENDED ABSTRACT.
DO NOT DISTRIBUTE ANYWHERE.

Mambaによる動き予測を用いたSAM2ベースの物体追跡

油谷 陽樹[1,a)]　丁 寧[1,b)]　玉木 徹[1,c)]

概要

物体追跡では，動画中の複数対象に対して一貫した ID を維持しながら，各フレームにおける位置やマスクを推定する必要がある．本研究では，SAM2 ベースの物体追跡に Mamba を用いた学習ベースの動き予測を導入する．実験では，学習ベースの動き予測が ID 維持および対応付け性能に与える影響を検証する．

1. はじめに

物体追跡は，動画中の対象をフレーム間で対応付け，各対象に一貫した ID を付与しながら追跡するタスクである．物体追跡では，各フレームにおける対象の位置やマスクを正確に推定するだけでなく，遮蔽，交差，類似外観の対象が存在する場面において，同一対象を安定して維持することが重要である．そのため，検出結果やセグメンテーション結果を時間方向にどのように関連付けするかが追跡性能を大きく左右する．

近年，Segment Anything Model (SAM) [13] およびその動画拡張である Segment Anything Model 2 (SAM2) [19] により，点や矩形などのプロンプトに基づいて高品質な対象マスクを生成し，動画中で伝播することが可能となった．SAM2 は，過去フレームの情報を参照しながら対象マスクを推定できる．この性質により，SAM2 は物体追跡への応用が期待されている．一方で，SAM2 を物体追跡に用いる場合，各対象のマスクを生成するだけでは不十分であり，複数対象の中でどの候補がどの ID に対応するかを安定して判断する必要がある．

SAM2 を物体追跡へ応用する研究として, SAMURAI [28] が提案されている．SAMURAI は SAM2 にカルマンフィルタを組み込み，対象の動き予測に基づいて候補マスクを選択する．これにより，SAM2 のマスク生成能力を活かしながら，対象の運動と整合する候補を選択できる．一方で, カルマンフィルタは事前に定めた状態方程式に基づく非学習型の予測器であり, 複雑な人物運動, 急な方向転換, 遮蔽後の再出現, カメラ運動を含む場面では十分な予測が困難となる場合がある．

そこで本研究では，SAM2 ベースの物体追跡に Mamba [5, 9, 14] を用いた学習ベースの動き予測を導入する．提案手法では，各対象の過去フレームにおけるバウンディングボックス系列を入力とし，Mamba により次フレームの対象位置を予測する．その後，予測位置と SAM2 が出力する候補マスクとの整合性を評価し，SAM2 の候補信頼度と統合することで最終的な候補を選択する．本研究の目的は，SAM2 の高品質なマスク生成能力を保ちつつ，カルマンフィルタでは扱いにくい複雑な運動を学習ベースで補助することで，困難な場面における追跡性能を向上させることである．

2. 関連研究

2.1 物体追跡

物体追跡では，動画中に存在する複数対象の位置を推定し，フレーム間で同一対象を対応付けることで軌跡を生成する．代表的な枠組みとして，tracking-by-detection（TBD）手法と tracking-by-attention（TBA）手法がある．TBD 手法では，検出器により得られたバウンディングボックスに対して，位置の重なり，外観特徴，動き予測などを用いて予測を行う [1, 2, 4, 18, 23, 24, 25, 30, 31]．この枠組みは構造が単純で拡張しやすい一方，検出ミスや対応付けミスが追跡結果に直接影響する．

一方，TBA 手法では，query を用いて検出と追跡を統合的に扱い，時系列方向に一貫した予測を行う [3, 7, 8, 17, 17, 22, 27, 29, 32]．この枠組みは検出と関連付けを相互に補正できる可能性を持つが，学習や推論の計算コストが大きくなる傾向がある．本研究では，これらの MOT 全体を新たに置き換えるのではなく，汎用セグメンテーションモデルである SAM2 を用いた追跡に対して，対象の運動を明示的に予測するモジュールを組み込むことに焦点を当てる．

[1] 名古屋工業大学
[a)] y.aburatani.799@nitech.jp
[b)] ding.ning@nitech.ac.jp
[c)] tamaki.toru@nitech.ac.jp

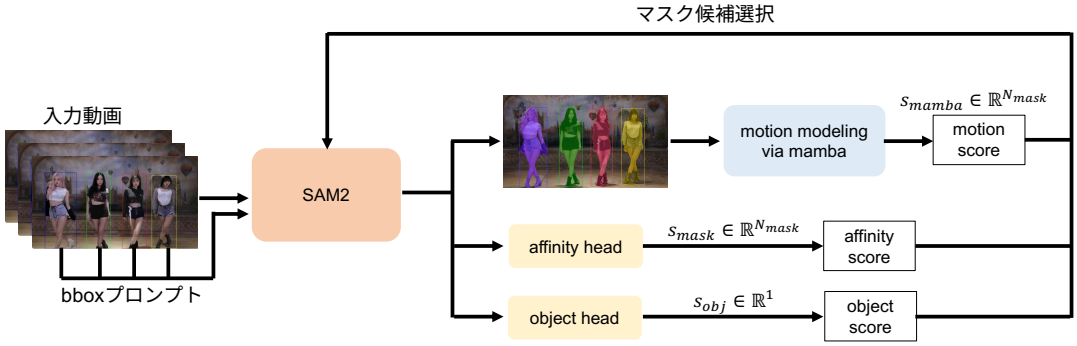


図 1: 提案手法の概要．SAM2 が出力する候補マスクに対して，Mamba を用いて次フレームの対象位置を予測する．その後，予測位置と候補マスクの整合性に基づき，対象 ID に対応する最終候補を選択する．

2.2 SAM2 を用いた物体追跡

SAM [13] は，点やバウンディングボックスなどのプロンプトに基づいて高品質なマスクを生成する汎用セグメンテーションモデルである．その動画拡張である SAM2 [19] では，過去フレームの情報を利用して対象マスクを動画中で伝播できるため，物体追跡への応用が期待されている．しかし，このような SAM2 ベースの物体追跡では，過去のマスク情報は利用されるものの，対象の将来位置を明示的に予測し，候補選択に反映する機構は限定的である．

SAM2 ベースの追跡に明示的な動き予測を組み込んだ手法として SAMURAI [28] がある．SAMURAI は，SAM2 が出力する複数の候補マスクに対して，カルマンフィルタにより予測した対象位置との整合性を評価し，追跡対象として最も妥当な候補を選択する．このように，SAMURAI は SAM2 のマスク生成能力に動き予測を組み合わせる点で有効である．

しかし，SAMURAI で用いられるカルマンフィルタは，事前に定めた状態方程式に基づく非学習型の予測器である．本研究では，SAMURAI に着想を得て，SAM ベース追跡における候補選択のうち，ボックス予測を担う部分に着目する．すなわち，候補マスク選択に用いられるボックス予測器を Mamba に置き換えることで，より柔軟な動き予測を行うことを目指す．

2.3 Mamba を用いた動き予測

Mamba [14] は，選択的状態空間モデルに基づく系列モデルであり，長い系列を効率的に扱える特徴を持つ．物体追跡において，対象の過去位置やバウンディングボックスの変化は次時刻の位置を予測するための重要な手がかりである．そのため，Mamba のような系列モデルを用いることで，カルマンフィルタのような固定的な状態遷移では扱いにくい運動パターンを学習できる可能性がある．

本論文では，Mamba を追跡の動き予測に用いる既存手法を，過去の一定長の履歴をまとめて入力する sliding window 型 [10, 11, 26] と，時刻ごとに入力を受け取りながら hidden state を持ち越す state carry 型 [6, 12, 15, 16, 20] の 2 種類に分類する．sliding window 型では，過去 L 時刻分のバウンディングボックス系列やその差分系列を入力し，次時刻の位置またはボックス差分を予測する．MambaTrack [26] などの手法では，このように過去のバウンディングボックス差分系列を用いて，将来の対象位置を予測する構成が用いられている．この方式は実装が比較的容易であり，固定長の運動履歴を明示的に利用できる一方，毎時刻ごとに履歴窓を構成する必要がある．一方，state carry 型では，各時刻の入力に基づいて Mamba の hidden state を逐次更新し，その状態を次時刻へ持ち越す．この方式では，固定長の履歴窓を毎回入力するのではなく，過去の運動情報を内部状態として保持しながら予測を行う．そのため，より長期的な運動文脈を利用できる可能性がある．

本研究では，SAM2 ベース追跡に組み込むボックス予測器として，Mamba に基づく動き予測を導入する．特に，既存の sliding window 型の Mamba 予測に加えて，hidden state を逐次更新する state carry 型の構成を検討する．これにより，SAM ベース追跡における候補マスク選択に対して，Mamba による学習ベースの動き予測がどのように寄与するかを検証する．

3. 提案手法

3.1 提案手法の概要

提案手法は，SAM2 により得られる候補マスク集合から，Mamba による動き予測と整合する候補を選択することで，複数物体追跡における ID 維持を安定化する手法である．図 1 に提案手法の概要を示す．各フレームにおいて，SAM2 は対象ごとに複数の候補マスクを出力する．各候補マスクからバウンディングボックスを計算し，それを Mamba に入力し，次フレームにおける対象位置を予測する．その後，予測位置と各候補マスクから得られるバウンディングボックスとの整合性を計算し，SAM2 の候補信頼度と統合することで最終候補を選択する．

3.2 SAM2 ベース追跡の定式化

フレーム t における対象 i に対して，SAM2 が出力する候補マスク集合を $\mathcal{M}_t^i = \{m_t^{i,1}, m_t^{i,2}, \ldots, m_t^{i,K}\}$ とする．ここで，K は候補マスク数である．各候補マスク $m_t^{i,k}$ から，対応するバウンディングボックス $b_t^{i,k}$ を計算する．また，SAM2 が候補 k に対して出力する信頼度を $q_t^{i,k}$ とする．

SAM2 ベース追跡では，各対象 i について過去に選択されたマスクおよびバウンディングボックスを履歴として保持する．本研究では，そのうちバウンディングボックス系列を動き予測の入力として用いる．この設計により，SAM2 の内部特徴やマスクデコーダ自体を大きく変更せず，既存の SAM2 追跡ループに動き予測器を追加できる．

3.3 Mamba によるボックス予測

フレーム t における対象 i のバウンディングボックスを $b_t^i = [c_x, c_y, w, h]$ と表す．ここで，(c_x, c_y) はバウンディングボックスの中心座標，w および h は幅と高さを表す．本研究では，対象の位置変化とスケール変化を考慮するため，時刻 t における状態ベクトル x_t^i を

$$x_t^i = [c_x, c_y, w, h, \Delta c_x, \Delta c_y, \Delta w, \Delta h] \tag{1}$$

と定義する．ここで，$\Delta c_x, \Delta c_y, \Delta w, \Delta h$ は前時刻との差分であり，対象の速度およびスケール変化を表す．

Mamba motion predictor は，対象 i の過去の状態系列を入力として，次時刻のバウンディングボックスまたはその差分を予測する．本稿では，次時刻のバウンディングボックス差分

$$\Delta\hat{b}_{t+1}^i = [\Delta\hat{c}_x, \Delta\hat{c}_y, \Delta\hat{w}, \Delta\hat{h}] \tag{2}$$

を予測し，現在時刻のボックス b_t^i に加算することで次時刻の予測ボックス

$$\hat{b}_{t+1}^i = b_t^i + \Delta\hat{b}_{t+1}^i. \tag{3}$$

を得る．このように，Mamba を SAM2 のマスク生成器としてではなく，バウンディングボックスの動き予測器として用いることで，SAM2 や SAMURAI の既存の追跡ループに比較的容易に組み込むことができる．

3.4 sliding window 型と state carry 型

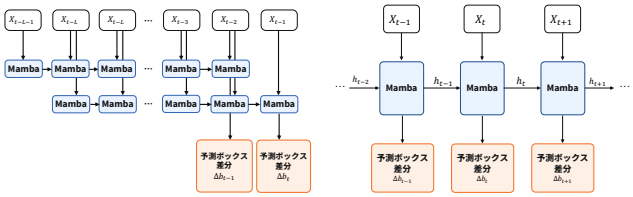
Mamba による動き予測の構成として，sliding window 型と state carry 型の 2 種類を扱う（図 2）．

3.4.1 sliding window 型

sliding window 型では（図 2(a)），対象 i について過去 L 時刻分の状態系列

$$X_{t-L+1}^i = \{x_{t-L+1}^i, \ldots, x_t^i\} \tag{4}$$

を追跡ループ側で保持し，Mamba に入力する．このとき，次時刻のボックス差分は次式で予測される．



(a) sliding window 型　　(b) state carry 型

図 2: Mamba による動き予測の 2 構成．sliding window 型では過去 L 時刻分の状態系列を毎時刻入力する．state carry 型では対象ごとに hidden state を保持し，各時刻の入力により逐次更新する．

$$\Delta\hat{b}_{t+1}^i = f_{\text{win}}(X_{t-L+1}^i). \tag{5}$$

この構成では，毎時刻，固定長の履歴窓を構成して予測を行う．既存の Mamba を用いた追跡手法では，過去数時刻分のバウンディングボックス差分系列を入力として用いる構成が多く，実装が比較的容易である．一方で，履歴長 L より前の情報は直接入力されないため，長期的な運動傾向を扱うには L の設計が重要となる．

3.4.2 state carry 型

state carry 型では（図 2(b)），対象 i ごとに Mamba の hidden stateh_t^i を保持する．各時刻において，現在の状態 x_t^i と前時刻の hidden stateh_{t-1}^i を用いて，次の hidden state

$$h_t^i = f_{\text{state}}(x_t^i, h_{t-1}^i). \tag{6}$$

を更新する．そして，更新された hidden state から次時刻のボックス差分

$$\Delta\hat{b}_{t+1}^i = g(h_t^i). \tag{7}$$

を予測する．この構成では，固定長の履歴窓を毎時刻入力するのではなく，過去の運動情報を hidden state として持ち越す．そのため，sliding window 型に比べて長期的な運動文脈を利用できる可能性がある．

3.5 動き予測に基づくマスク候補選択

フレーム t において，Mamba により予測されたバウンディングボックス $\hat{b}_t^i$ と，SAM2 が出力した各候補 $b_t^{i,k}$ との整合性を評価する．本手法では，予測位置と候補位置の一致度として IoU を用いる．候補 k の選択スコア $s_t^{i,k}$ を次式で定義する．

$$s_t^{i,k} = \lambda s_{\text{mamba}}^{i,k} + (1-\lambda) s_{\text{mask}}^{i,k} \tag{8}$$

ここで，λ は動き予測との整合性と SAM2 の候補信頼度の重みを調整する係数である．最終的な候補 k^* は，スコアが最大となる候補として次式により選択する．

$$k^* = \arg\max_k s_t^{i,k}. \tag{9}$$

そして選択されたマスク m_t^{i,k^*} をフレーム t における対象 i

表 1: DanceTrack における追跡性能の比較．数値は実験後に記入する．

Method	HOTA↑	DetA↑	AssA↑	IDF1↑	IDSW↓
SAM2	0.46	0.38	0.56	0.58	1618
SAMURAI (KF)	0.54	0.48	0.61	0.62	1517
Ours (Mamba-window)	0.53	0.47	0.61	0.61	1552
Ours (Mamba-state)	–	–	–	–	–

の追跡結果とし，そのバウンディングボックスを次フレーム以降の動き予測の履歴に追加する．

この候補選択は，SAMURAI におけるカルマンフィルタに基づく候補選択と同様の枠組みである．

4. 実験

4.1 実験設定

提案手法の有効性を検証するため，DanceTrack [21] を用いて評価を行う．DanceTrack は，類似した外観を持つ人物が複雑に移動する動画を含むため，外観特徴だけに依存しないデータアソシエーションや動き予測の評価に適している．本研究では，SAM2 ベースの追跡において動き予測を導入した場合に，ID 維持性能がどのように変化するかを検証する．

評価指標として，HOTA，DetA，AssA，IDF1，IDSW を用いる．HOTA は検出性能と関連付け性能を総合的に評価する指標である．DetA は検出性能，AssA はフレーム間の関連付け性能を表す．本研究では，動き予測による候補選択の改善を目的とするため，特に AssA，IDF1，IDSW に着目する．

比較手法として，SAM2 が出力する候補信頼度のみを用いる SAM2 score only，カルマンフィルタに基づくボックス予測を用いる SAMURAI (KF)，および Mamba に基づくボックス予測を用いる提案手法を評価する．Mamba に基づく手法については，過去 L 時刻分の状態系列を入力する sliding window 型と，対象ごとに hidden state を持ち越す state carry 型の 2 種類を比較する．これにより，非学習型の動き予測と学習ベースの動き予測の違いに加えて，Mamba における系列情報の保持方法が追跡性能に与える影響を検証する．

4.2 定量的評価

表 1 に，DanceTrack における追跡性能の比較を示す．なお，state carry 型については現在実装および評価を進めている段階であるため，表内に結果は載せられていない．

Ours (Mamba-window) では，SAMURAI (KF) と同程度の AssA および IDF1 を示した．一方で，HOTA および DetA は SAMURAI (KF) をわずかに下回った．この結果は，過去のバウンディングボックス系列を用いた Mamba による学習ベースの動き予測が，カルマンフィルタと同様に候補選択へ利用可能であることを示している．ただし，今回の設定では，Mamba による予測がカルマンフィルタを明確に上回るまでには至らなかった．

この要因として，sliding window 型では過去 L 時刻分の固定長履歴のみを入力するため，履歴長より前の運動情報を直接利用できないことが考えられる．また，本研究では SAM2 のマスク生成器やメモリ機構は変更しておらず，候補マスク集合から最終候補を選択する部分のみを変更している．そのため，提案手法の効果は主に候補選択および関連付け性能に現れると考えられる．今後は，履歴長 L や入力特徴量の設計を検討するとともに，hidden state を逐次保持する state carry 型の Mamba 予測器を導入し，より長期的な運動文脈を利用した候補選択を検証する．

5. おわりに

本研究では，SAM2 ベースの物体追跡に対して，Mamba を用いた学習ベースの動き予測を組み込む手法を提案した．提案手法では，SAM2 が出力する候補マスクに対して，過去のバウンディングボックス系列から予測した対象位置との整合性を評価し，最終候補を選択する．DanceTrack を用いた実験では，sliding window 型の Mamba 予測器を候補マスク選択に導入することで，カルマンフィルタに基づく候補選択と同程度の関連付け性能が得られることを確認した．

一方で，今回の設定では，Mamba による動き予測がカルマンフィルタを明確に上回るまでには至らなかった．今後は，入力する履歴長や状態表現の改善に加えて，hidden state を対象ごとに保持する state carry 型の Mamba 予測器を導入することで，より長期的な運動文脈を利用した追跡を検討する．また，遮蔽や対象の再出現時における状態更新の設計，および SAM2 のメモリ選択との統合についても検討する．

謝辞

本研究の一部は，JSPS 科研費 JP25K03138 の助成を受けた．

参考文献

[1] Bergmann, P., Meinhardt, T. and Leal-Taixe, L.: Tracking Without Bells and Whistles, *Proceedings of the IEEE/CVF International Conference on Computer Vi-*

sion (ICCV) (2019).

[2] Bewley, A., Ge, Z., Ott, L., Ramos, F. and Upcroft, B.: Simple Online and Realtime Tracking, *CoRR*, Vol. abs/1602.00763 (2016).

[3] Cai, J., Xu, M., Li, W., Xiong, Y., Xia, W., Tu, Z. and Soatto, S.: MeMOT: Multi-Object Tracking With Memory, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 8090–8100 (2022).

[4] Cao, J., Pang, J., Weng, X., Khirodkar, R. and Kitani, K.: Observation-Centric SORT: Rethinking SORT for Robust Multi-Object Tracking, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9686–9696 (2023).

[5] Dao, T. and Gu, A.: Transformers are SSMs: Generalized Models and Efficient Algorithms Through Structured State Space Duality, *Proceedings of the 41st International Conference on Machine Learning* (Salakhutdinov, R., Kolter, Z., Heller, K., Weller, A., Oliver, N., Scarlett, J. and Berkenkamp, F., eds.), Proceedings of Machine Learning Research, Vol. 235, PMLR, pp. 10041–10071 (2024).

[6] Fu, Z., Han, X., Jia, M., Zeng, Q., Zahng, M., Wang, C., Meng, W., Zhang, X. et al.: DMTrack: Deformable State-Space Modeling for UAV Multi-Object Tracking with Kalman Fusion and Uncertainty-Aware Association, *arXiv preprint arXiv:2510.17860* (2025).

[7] Gao, R., Qi, J. and Wang, L.: Multiple Object Tracking as ID Prediction, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 27883–27893 (2025).

[8] Gao, R. and Wang, L.: MeMOTR: Long-Term Memory-Augmented Transformer for Multi-Object Tracking, *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 9901–9910 (2023).

[9] Gu, A. and Dao, T.: Mamba: Linear-Time Sequence Modeling with Selective State Spaces, *First Conference on Language Modeling* (2024).

[10] Hu, B., Luo, R., Liu, Z., Wang, C. and Liu, W.: TrackSSM: A General Motion Predictor by State-Space Model (2024).

[11] Huang, H.-W., Yang, C.-Y., Chai, W., Jiang, Z. and Hwang, J.-N.: MambaMOT: State-Space Model as Motion Predictor for Multi-Object Tracking, *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 1–5 (2025).

[12] Kang, B., Chen, X., Lai, S., Liu, Y., Liu, Y. and Wang, D.: Exploring Enhanced Contextual Information for Video-Level Object Tracking, *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 39, No. 4, pp. 4194–4202 (2025).

[13] Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, C., Gustafson, L., Xiao, T., Whitehead, S., Berg, A. C., Lo, W.-Y., Dollar, P. and Girshick, R.: Segment Anything, *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 4015–4026 (2023).

[14] Lahoti, A., Li, K., Chen, B., Wang, C., Bick, A., Kolter, J. Z., Dao, T. and Gu, A.: Mamba-3: Improved Sequence Modeling using State Space Principles, *The Fourteenth International Conference on Learning Representations* (2026).

[15] Li, X., Zhong, B., Liang, Q., Li, G., Mo, Z. and Song, S.: MambaLCT: Boosting Tracking via Long-term Context State Space Model, *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 39, No. 5, pp. 4986–4994 (2025).

[16] Ma, Y., Yang, D., He, Z., Yang, W. and Zhang, T.: SMTrack: State-Aware Mamba for Efficient Temporal Modeling in Visual Tracking, *IEEE Transactions on Image Processing*, Vol. 35, pp. 2249–2261 (2026).

[17] Meinhardt, T., Kirillov, A., Leal-Taixé, L. and Feichtenhofer, C.: TrackFormer: Multi-Object Tracking With Transformers, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 8844–8854 (2022).

[18] Pang, J., Qiu, L., Li, X., Chen, H., Li, Q., Darrell, T. and Yu, F.: Quasi-Dense Similarity Learning for Multiple Object Tracking, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 164–173 (2021).

[19] Ravi, N., Gabeur, V., Hu, Y.-T., Hu, R., Ryali, C., Ma, T., Khedr, H., Rädle, R., Rolland, C., Gustafson, L., Mintun, E., Pan, J., Alwala, K. V., Carion, N., Wu, C.-Y., Girshick, R., Dollar, P. and Feichtenhofer, C.: SAM 2: Segment Anything in Images and Videos (2025).

[20] Segu, M., Piccinelli, L., Li, S., Yang, Y.-H., Gool, L. V. and Schiele, B.: Samba: Synchronized Set-of-Sequences Modeling for Multiple Object Tracking, *The Thirteenth International Conference on Learning Representations* (2025).

[21] Sun, P., Cao, J., Jiang, Y., Yuan, Z., Bai, S., Kitani, K. and Luo, P.: DanceTrack: Multi-Object Tracking in Uniform Appearance and Diverse Motion, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 20993–21002 (2022).

[22] Sun, P., Jiang, Y., Zhang, R., Xie, E., Cao, J., Hu, X., Kong, T., Yuan, Z., Wang, C. and Luo, P.: TransTrack: Multiple-Object Tracking with Transformer, *CoRR*, Vol. abs/2012.15460 (2020).

[23] Wang, Z., Zheng, L., Liu, Y., Li, Y. and Wang, S.: Towards Real-Time Multi-Object Tracking, *Computer Vision – ECCV 2020* (Vedaldi, A., Bischof, H., Brox, T. and Frahm, J.-M., eds.), Cham, Springer International Publishing, pp. 107–122 (2020).

[24] Wang, Z., Zheng, L., Liu, Y., Li, Y. and Wang, S.: Towards Real-Time Multi-Object Tracking, *Computer Vision – ECCV 2020* (Vedaldi, A., Bischof, H., Brox, T. and Frahm, J.-M., eds.), Cham, Springer International Publishing, pp. 107–122 (2020).

[25] Wojke, N., Bewley, A. and Paulus, D.: Simple online and realtime tracking with a deep association metric, *2017 IEEE International Conference on Image Processing (ICIP)*, pp. 3645–3649 (2017).

[26] Xiao, C., Cao, Q., Luo, Z. and Lan, L.: MambaTrack: a simple baseline for multiple object tracking with State Space Model, *ACM Multimedia 2024* (2024).

[27] yan, F., Luo, W., Zhong, Y., Gan, Y. and Ma, L.: COMOT: Boosting End-to-end Transformer-based Multi-Object Tracking via Coopetition Label Assignment and Shadow Sets, *The Thirteenth International Conference on Learning Representations* (2025).

[28] Yang, C.-Y., Huang, H.-W., Chai, W., Jiang, Z. and Hwang, J.-N.: SAMURAI: Adapting Segment Anything Model for Zero-Shot Visual Tracking with Motion-Aware Memory (2024).

[29] Zeng, F., Dong, B., Zhang, Y., Wang, T., Zhang, X. and Wei, Y.: MOTR: End-to-End Multiple-Object Tracking with Transformer, *Computer Vision – ECCV 2022* (Avidan, S., Brostow, G., Cissé, M., Farinella, G. M. and

Hassner, T., eds.), Cham, Springer Nature Switzerland, pp. 659–675 (2022).

[30] Zhang, Y., Sun, P., Jiang, Y., Yu, D., Weng, F., Yuan, Z., Luo, P., Liu, W. and Wang, X.: ByteTrack: Multi-object Tracking by Associating Every Detection Box, *Computer Vision – ECCV 2022* (Avidan, S., Brostow, G., Cissé, M., Farinella, G. M. and Hassner, T., eds.), Cham, Springer Nature Switzerland, pp. 1–21 (2022).

[31] Zhang, Y., Wang, C., Wang, X., Zeng, W. and Liu, W.: FairMOT: On the Fairness of Detection and Re-identification in Multiple Object Tracking, *Int. J. Comput. Vision*, Vol. 129, No. 11, p. 3069–3087 (2021).

[32] Zhang, Y., Wang, T. and Zhang, X.: MOTRv2: Bootstrapping End-to-End Multi-Object Tracking by Pretrained Object Detectors, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 22056–22065 (2023).