状態保持型 Mamba を用いた SAM2 ベース物体追跡

○油谷陽樹 †, 丁寧 †, 玉木徹 †
†：名古屋工業大学
y.aburatani.799@nitech.jp, ding.ning@nitech.ac.jp, tamaki.toru@nitech.ac.jp

＜キーワード＞物体追跡，Mamba，SAM2

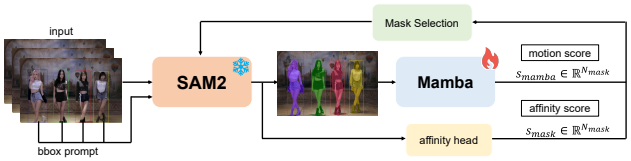


図 1: 提案手法の概要.

1. はじめに

物体追跡は, 動画中の対象をフレーム間で対応付け, 各対象に一貫した ID を付与しながら追跡するタスクである. 特に, 遮蔽や対象同士の交差, 類似した外観を持つ対象が存在する場面では, 各フレームにおける対象位置を正確に推定するだけでなく, 同一対象の ID を安定して維持することが重要となる.

近年, Segment Anything Model 2 (SAM2) [1] により, プロンプトとして与えた対象のマスクを高精度に生成し, 過去フレームの情報を利用しながら動画中で伝播することが可能となった. 一方, SAM2 を物体追跡に利用する場合, 複数の候補マスクの中から追跡対象に対応する候補を安定して選択する必要がある.

SAM2 を物体追跡へ応用した SAMURAI [2] では, カルマンフィルタによる対象位置の予測を候補マスク選択に導入している. これにより, SAM2 のマスク生成能力と対象の運動情報を組み合わせた追跡を実現している. しかし, カルマンフィルタはあらかじめ定めた状態遷移モデルに基づくため, 急な方向転換などを含む複雑な人物運動を十分に表現できない場合がある.

そこで本研究では, SAM2 ベースの物体追跡に Mamba [3] を用いた学習ベースの動き予測を導入する. 提案手法では, 各対象の過去のバウンディングボックス系列から次フレームの対象位置を予測し, 予測位置と SAM2 が生成する候補マスクとの整合性に基づいて最終的な候補を選択する. さらに, Mamba の内部状態を利用して過去の運動情報を継続的に保持することで, 固定的な状態遷移モデルでは扱いにくい複雑な運動に対応することを目指す.

2. 提案手法

2.1. SAM2 と Mamba を用いた物体追跡

図1に提案手法の概要を示す. 提案手法では, SAM2 が生成する複数の候補マスクに対して, Mamba による動き予測との整合性を評価し, 対象 ID に対応する候補を選択する.

フレーム t における対象 i のバウンディングボックスを

$$b_t^i = [c_x, c_y, w, h] \tag{1}$$

とする. Mamba による動き予測器では, 過去のバウンディングボックスを入力として, 次フレームにおけるボックス差分 $\Delta\hat{b}_{t+1}^i$ を予測し,

$$\hat{b}_{t+1}^i = b_t^i + \Delta\hat{b}_{t+1}^i \tag{2}$$

として次フレームの対象位置を得る.

本研究では, Mamba による系列情報の保持方法として 2 種類の構成を比較する. sliding window 型では, 過去 L フレーム分のバウンディングボックス系列を毎フレーム入力し, 次フレームの位置を予測する. 一方, state carry 型では, 各対象について Mamba の hidden state を保持し, 新たな観測が得られるたびに状態を逐次更新する. このため, state carry 型では固定長の履歴窓を毎回構成することなく, 過去の運動情報を内部状態として継続的に利用できる.

2.2. 動き予測に基づく候補マスク選択

フレーム t において, SAM2 が対象 i に対して生成した候補 k のバウンディングボックスを $b_t^{i,k}$ とする. Mamba による予測ボックス $\hat{b}_t^i$ と候補ボックス $b_t^{i,k}$ との IoU を, 動き予測に基づくスコア $s_{\text{mamba}}^{i,k}$ とする. また, SAM2 が出力する候補の信頼度を $s_{\text{mask}}^{i,k}$ とし, 最終的な候補選択スコアを

$$s_t^{i,k} = \lambda s_{\text{mamba}}^{i,k} + (1-\lambda) s_{\text{mask}}^{i,k} \tag{3}$$

と定義する. ここで, λ は動き予測と SAM2 の候補信頼度の重みを調整する係数である. 最終的な候補は

表 1: DanceTrack における追跡性能の比較.

Method	HOTA↑	DetA↑	AssA↑	IDF1↑	IDSW↓
SAM2	51.3	45.5	58.3	58.5	1618
SAMURAI	54.1	47.9	61.5	62.3	**1517**
Mamba-window	53.3	46.8	61.0	61.3	1552
Mamba-state	**55.5**	**49.6**	**62.5**	**64.2**	1535

$$k^* = \arg\max_k s_t^{i,k} \tag{4}$$

として選択する. 選択されたマスクを対象 i の追跡結果とし, そのバウンディングボックスを以降の動き予測に利用する. これにより, SAM2 のマスク生成機構自体を変更することなく, 学習ベースの動き予測を既存の追跡ループへ導入できる.

3. 実験

3.1. 実験設定

提案手法の有効性を検証するため, DanceTrack [4] を用いて評価を行った. DanceTrack には, 類似した外観を持つ人物が複雑に移動する映像が多く含まれており, 外観だけに依存しない動き予測やデータアソシエーションの評価に適している.

比較手法として, SAM2 の候補信頼度を用いる SAM2, カルマンフィルタによる動き予測を用いる SAMURAI, および Mamba を用いる提案手法を評価した. 提案手法については sliding window 型と state carry 型の 2 種類を比較した. 評価指標には HOTA, DetA, AssA, IDF1, IDSW を用いた. 特に, 本研究では候補マスクの対応付け改善を目的としているため, AssA および IDF1 に着目する.

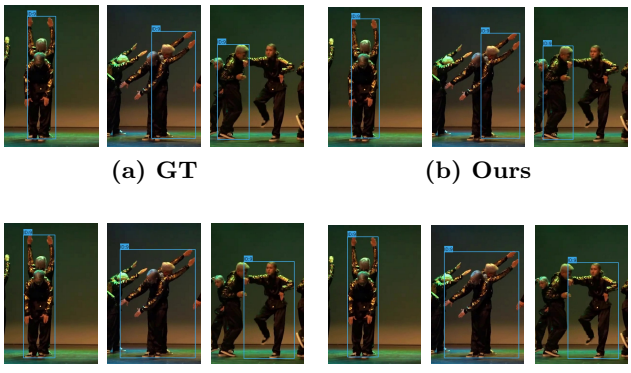
3.2. 定量的評価

表1に DanceTrack における追跡性能を示す.

sliding window 型では, AssA は SAMURAI と同程度となった一方, HOTA および IDF1 は SAMURAI をわずかに下回った. このことから, Mamba を動き予測器として導入するだけでは, カルマンフィルタを上回る追跡性能が必ずしも得られないことが分かる.

一方, state carry 型では HOTA が 55.5 となり, SAMURAI の 54.1 を上回った. また, DetA は 49.6, AssA は 62.5, IDF1 は 64.2 となり, いずれも SAMURAI より高い値を示した. この結果から, 対象ごとの運動情報を hidden state としてフレーム間で引き継ぐことが, 候補マスクの対応付けおよび ID 維持に有効であると考えられる.

固定長の履歴を毎時刻入力する sliding window 型に対して, state carry 型では対象の運動履歴を内部状態として連続的に保持できるため, より長い時間範囲の運動傾向を候補選択に利用できた可能性がある. 一方, IDSW については SAMURAI が最も少なく, state carry 型でも改善の余地が残されている.



(a) GT (b) Ours

(c) SAM2 (d) SAMURAI

図 2: DanceTrack における追跡結果の比較.

3.3. 定性的評価

図2に, DanceTrack における追跡結果の例を示す. 対象同士が接近・交差する場面において, SAM2 および SAMURAI では推定されたバウンディングボックスが対象からずれる場面が見られる. 一方, state carry 型の提案手法では, 過去の運動情報を hidden state として保持することで, 対象の運動に沿った追跡結果が得られている.

4. おわりに

本研究では, SAM2 ベースの物体追跡に Mamba を用いた学習ベースの動き予測を導入した. DanceTrack を用いた実験では, state carry 型が HOTA, DetA, AssA, IDF1 の各指標で SAMURAI を上回り, 運動情報を内部状態として継続的に保持することの有効性を確認した. 今後は, hidden state の更新方法に加えて, SAM2 のデコーダへの Mamba 導入を検討する.

謝辞

本研究の一部は, JSPS 科研費 JP25K03138 の助成を受けた.

参考文献

[1] Ravi et al., SAM 2: Segment Anything in Images and Videos. *ICLR2025*.

[2] Yang et al., SAMURAI: Adapting Segment Anything Model for Zero-Shot Visual Tracking with Motion-Aware Memory. *arXiv:2411.11922*, 2024.

[3] Gu and Dao, Mamba: Linear-Time Sequence Modeling with Selective State Spaces. *COLM2024*.

[4] Sun et al., DanceTrack: Multi-Object Tracking in Uniform Appearance and Diverse Motion. *CVPR2022*.