Mamba は動画の「過去」を どう持つべきか？

油谷陽樹（名工大 玉木・丁研）

2026/11/19

本紹介の概要



■ 背景

- 動画を1フレームずつ処理するモデルは，過去フレームの情報をどこかに持って使う必要がある
- Mamba（SSM）は系列を**固定サイズの state** に圧縮しながら読む

■ 今日の問い：過去の情報を

- ① **何に紐付けるか**（位置・軌跡・物体）
- ② **どこまで信じるか**（無条件・類似度で選ぶ・信頼度で切り替える）

MambaOut
前提：要るか？

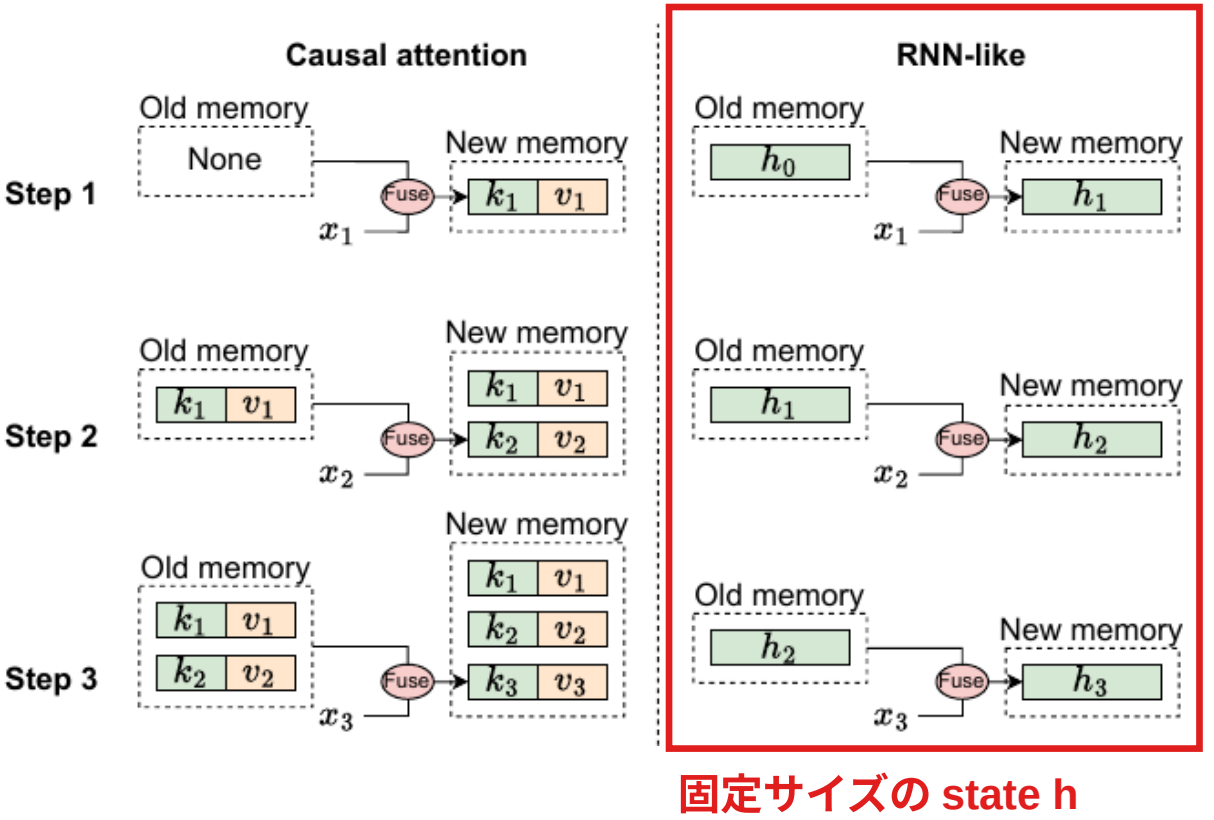
TV3S
位置に紐付けて持ち越す

TS-Mamba
軌跡に沿って集める

Memory as Dynamics
予測を信頼度で選ぶ

事前知識：SSM の state

- SSM（状態空間モデル）
  - $h_t = \bar{A}\, h_{t-1} + \bar{B}\, x_t$
  - $y_t = C\, h_t$
  - 過去を**固定サイズの state** h に押し込み，毎ステップ更新
- Mamba [Gu+, COLM2024]
  - Δ・B・C を入力から決め，何を残すかを選べる
- 右図：attention との違い
  - attention：過去を全部持つ（lossless，コスト増）
  - SSM：サイズ一定（**lossy**，コスト一定）



MambaOut [Yu+, CVPR2025]

MambaOut:
Do We Really Need Mamba for Vision?

Weihao Yu, Xinchao Wang

CVPR 2025

前提：画像認識に Mamba は要るか？ SSM を抜いて確かめる

MambaOut
前提：要るか？

TV3S
位置に紐付けて持ち越す

TS-Mamba
軌跡に沿って集める

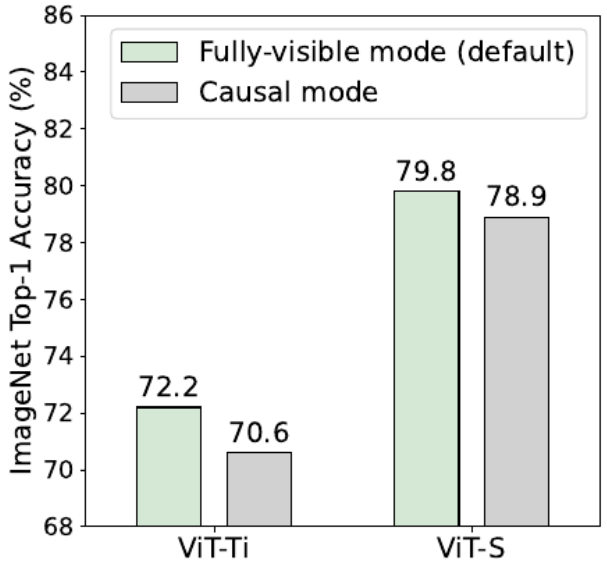
Memory as Dynamics
予測を信頼度で選ぶ

問い：Mamba が向くタスク



- 著者の整理
  - 特性1：**長い系列**を扱う（state は lossy だが，コスト一定）
  - 特性2：**causal** な token mixing（SSM は本質的に causal）
- 「長い」の目安：L > 6D
  - L：token 数，D：channel 数，ViT-S なら 2304
- 仮説
  - 1：分類に SSM は不要
  - 2：検出・分割は検討の余地あり

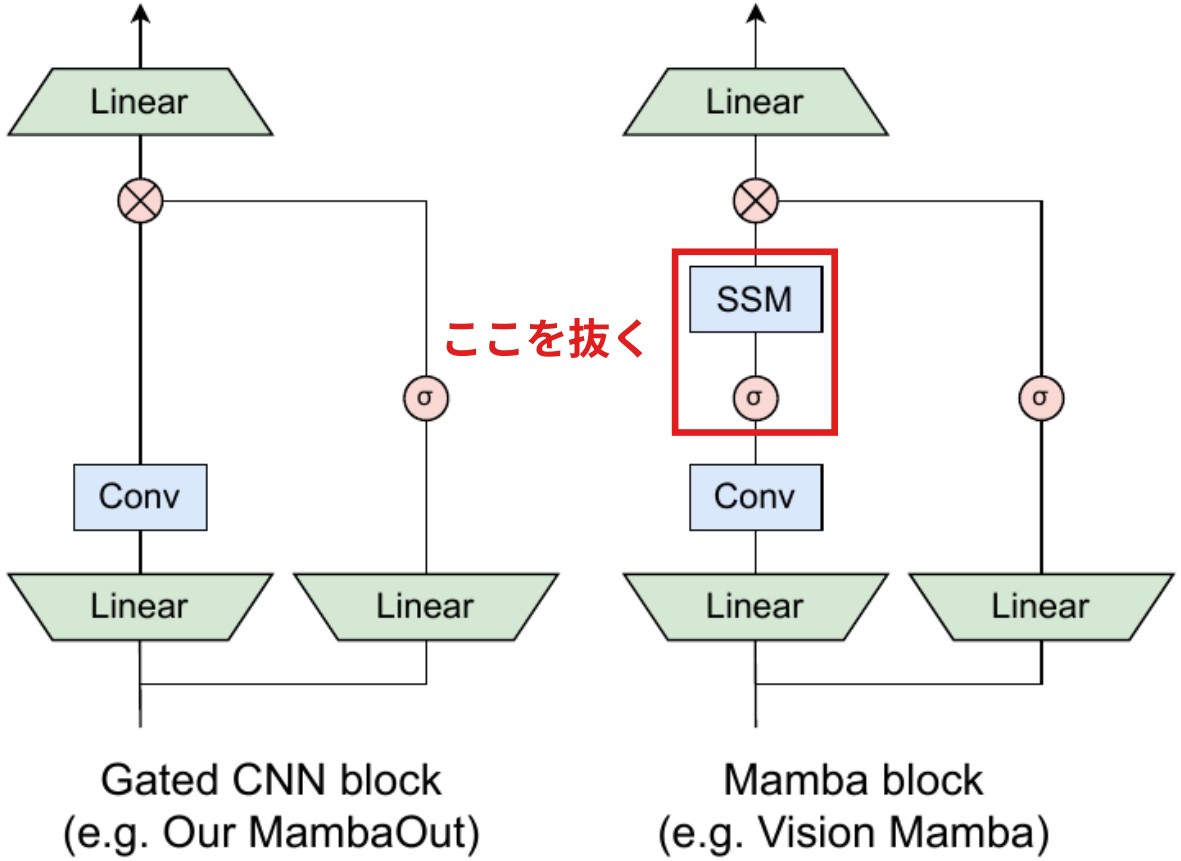
タスク	token 数	長い？	causal？
ImageNet 分類	196	×	×
COCO・ADE20K	約 4K	◯	×



ViT を causal にすると精度が下がる
72.2 → 70.6（Ti），79.8 → 78.9（S）

ViT [Dosovitskiy+, ICLR2021]

手法：SSM を抜いた Gated CNN



- token mixer の比較
  - Gated CNN [Dauphin+, ICML2017]：Conv(Z)
  - Mamba：SSM(σ(Conv(Z)))
  - 違いは **SSM（と直前の σ）** だけ
- 検証の考え方
  - SSM を抜いても同じくらい性能が出るなら，そのタスクに SSM は要らない
- 実装
  - 7×7 depthwise conv，4 stage 構成

実験設定：MambaOut



■ データセット・評価指標

- ImageNet [Deng+, CVPR2009]（約 130 万枚，224^2）：top-1 精度
- COCO [Lin+, ECCV2014]：AP^b・AP^m
- ADE20K [Zhou+, CVPR2017]（150 クラス）：mIoU

■ 下流タスクの枠組み

- Mask R-CNN [He+, ICCV2017]（COCO）
- UperNet [Xiao+, ECCV2018]（ADE20K）

■ 学習設定

- ImageNet：DeiT [Touvron+, ICML2021] に従う（蒸留なし），AdamW，batch 4096，lr 0.004，TPU v3
- COCO：12 epochs　ADE20K：160,000 iterations（ともに AdamW，lr 0.0001，batch 16，NVIDIA 4090 × 4）

■ 比較手法

- VMamba [Liu+, NeurIPS2024]
- LocalVMamba [Huang+, arXiv2024] など

定量的評価：分類は並び，検出は届かない



Model	Token Mixing Type	Param (M)	Test@224^2 MAC (G)	Test@224^2 Acc (%)
VMamba-S [56]	Conv + SSM	44	11.2	83.5
LocalVMamba-S [41]	Conv + SSM	50	11.4	83.7
PlainMamba-L2 [96]	Conv + SSM	25	8.1	81.6
VMambaV3-S* [55]	Conv + SSM	50	8.7	83.6
MambaOut-Small	Conv	48	9.0	**84.1**

検出・セグメンテーション（Table 2・3 から Tiny を抜粋）

Backbone	AP^b	AP^m	mIoU (SS)
VMamba-T	46.5	42.1	47.3
LocalVMamba-T	46.7	42.2	47.9
MambaOut-T（SSM なし）	45.1	41.0	47.4

- ImageNet（仮説1）
  - Small：**84.1**% vs LocalVMamba-S 83.7%（MACs は 79%）
  - Tiny：82.7% で同値
- COCO・ADE20K（仮説2）
  - VMamba-T に AP^b −1.4，AP^m −1.1
  - ADE20K は LocalVMamba-T に −0.5 mIoU
  - 差は小さく，相手によっては MambaOut が上

まとめ：MambaOut



- SSM は「長く，causal な系列」で使う
  - state は固定サイズで lossy，長い系列でもコスト一定なのが強み
  - 分類では不要，検出・セグメンテーションは検討の余地あり
- 限界
  - Tiny では同値，検出での差も 1 ポイント前後で，SSM が勝つ理由は切り分けられていない
- 動画に当てはめると（発表者の解釈）
  - オンライン動画の時間方向は**長く，causal** → 2つの特性を両方満たしうる

次論文：動画の時間方向で，過去をどう持つか？
→ 位置に紐付けて持ち越す（TV3S）

Exploiting Temporal State Space Sharing for Video Semantic Segmentation (TV3S)

Syed Ariff Syed Hesham, Yun Liu, Guolei Sun, Henghui Ding, Jing Yang, Ender Konukoglu, Xue Geng, Xudong Jiang

CVPR 2025

過去の情報を位置に紐付けて持ち越す動画セグメンテーション

MambaOut
前提：要るか？

TV3S
位置に紐付けて持ち越す

TS-Mamba
軌跡に沿って集める

Memory as Dynamics
予測を信頼度で選ぶ

概要：過去を state で持ち越す

■ 従来手法の課題

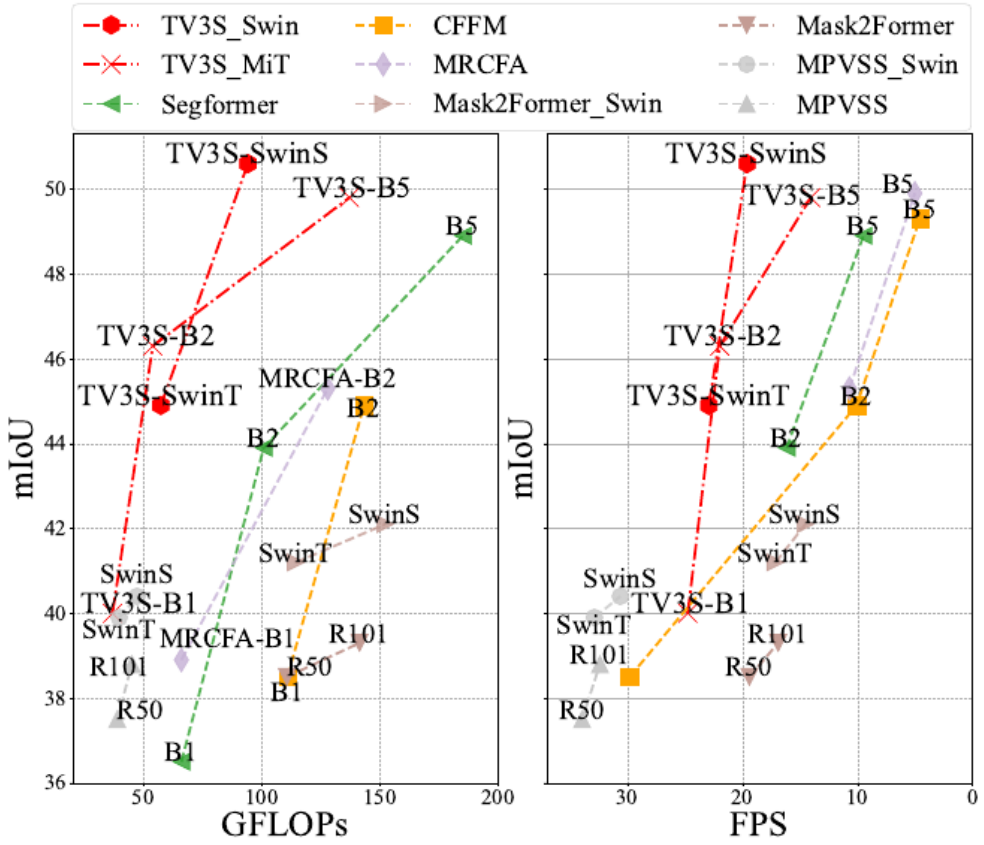
- 1フレームずつ・短い窓 → 時間の文脈が短い
- 過去の特徴を保持（feature pool）→ メモリが重い

■ 提案：TV3S

- window ごとに Mamba の state を **フレーム間で持ち越す**
- shift で隣の window とも混ぜる
- 推論はオンライン

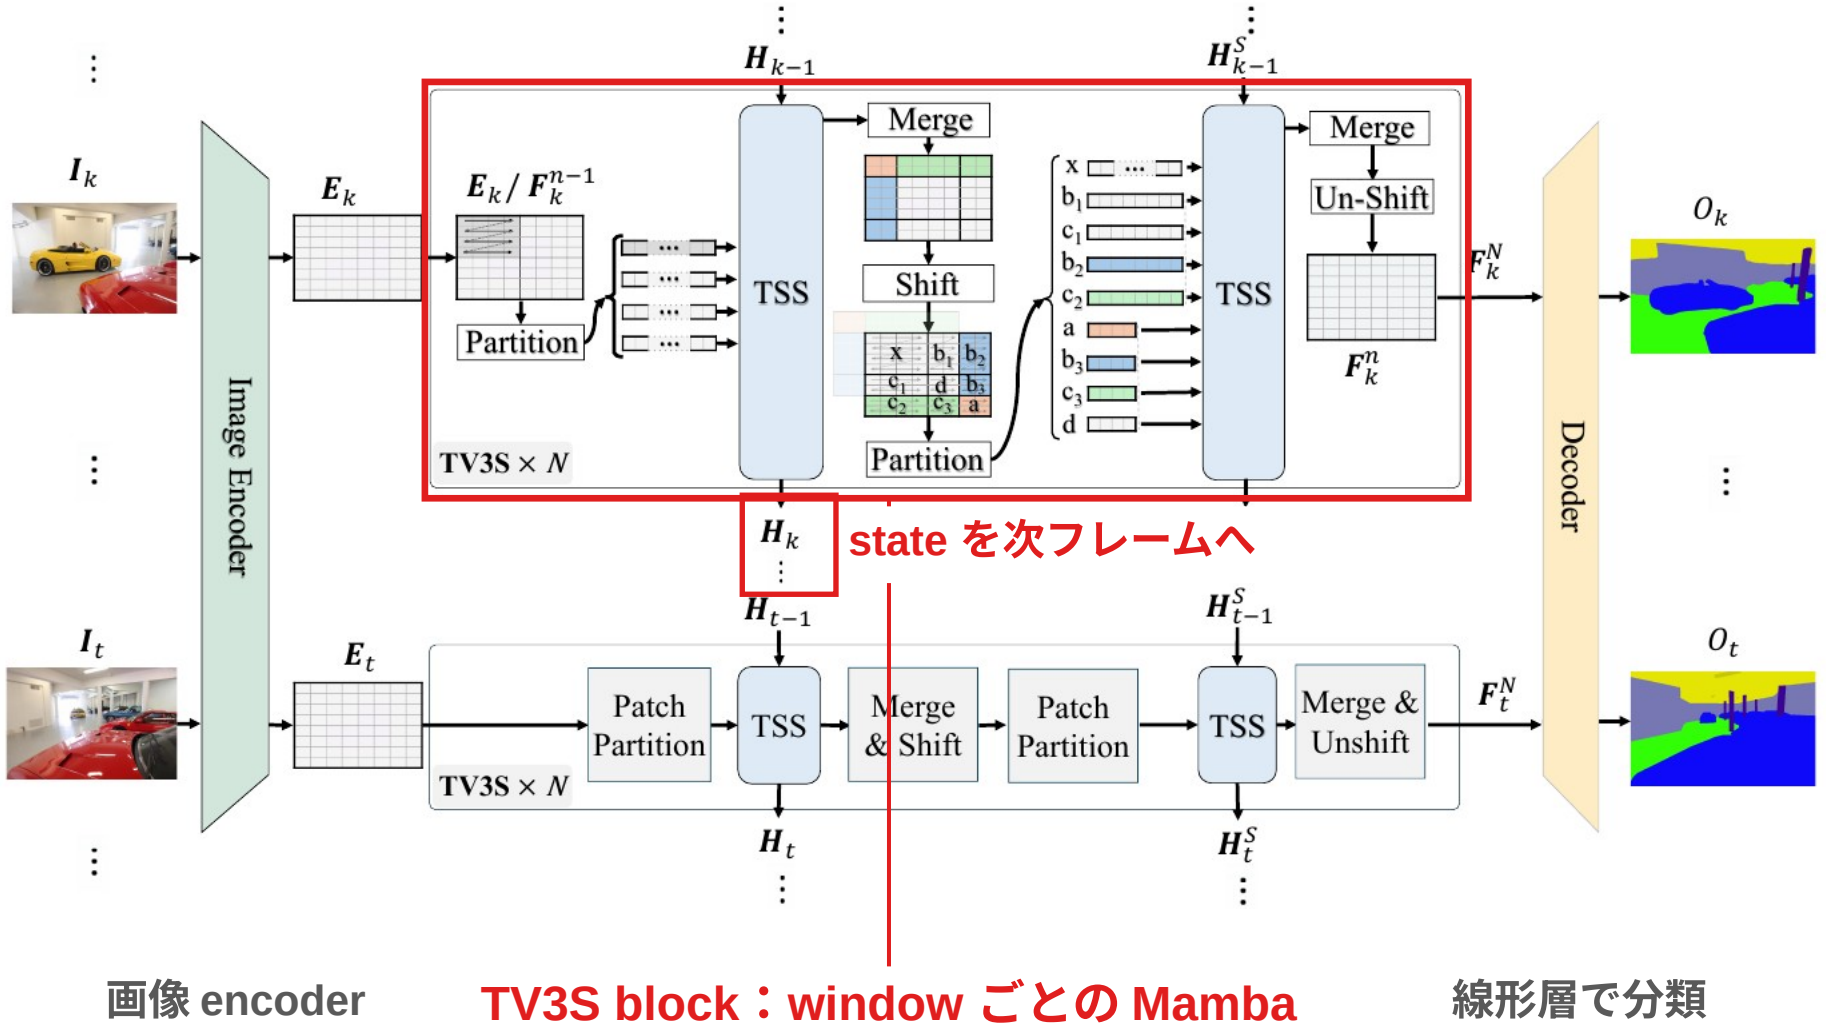
■ 前提（著者）

- フレーム間の変化は小さい → window の位置は固定

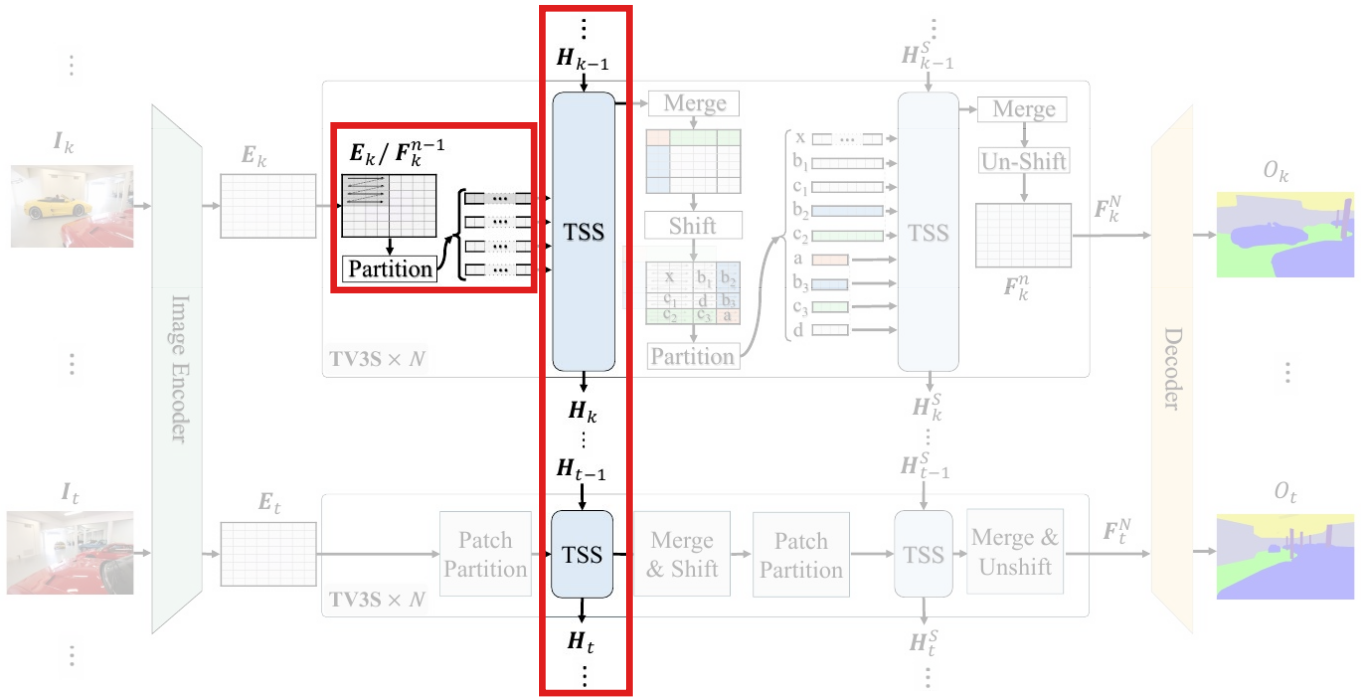


赤い線が TV3S：同程度の計算量・速度で mIoU が高い（VSPW）

全体図：TV3S


I_k
I_t
Image Encoder
E_k
E_t
E_k / F_k^{n-1}
Partition
TSS
Merge
Shift
Partition
Un-Shift
TV3S × N
H_{k-1}
H_k
H_{t-1}
H_t
H_{k-1}^S
H_t^S
F_k^N
F_t^N
F_k^n
Patch Partition
Merge & Shift
Merge & Unshift
Decoder
O_k
O_t
state を次フレームへ
画像 encoder
TV3S block：window ごとの Mamba
線形層で分類

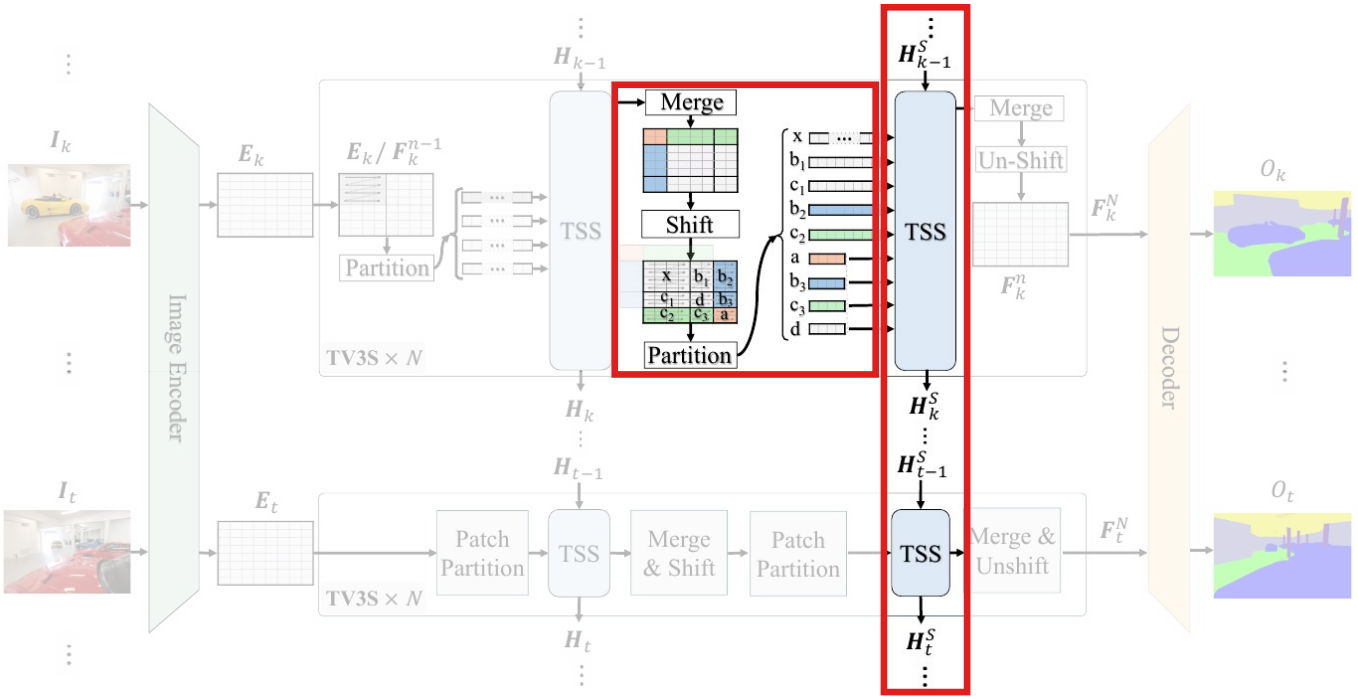
state は window ごとに持ち越す



$$\begin{aligned} \boldsymbol{H}_t^{i,j} &= f_A(\Delta, \boldsymbol{A}_s)\boldsymbol{H}_{t-1}^{i,j} + f_B(\Delta, \boldsymbol{A}_s, \boldsymbol{B}_s)\hat{\boldsymbol{P}}_t^{i,j}, \\ \boldsymbol{F}_t^{i,j} &= \boldsymbol{C}_s\boldsymbol{H}_t^{i,j}. \end{aligned} \tag{2}$$

- 20×20 の window に分割
  - 入力画像で約 160×160 画素（公開コードの設定）
- state を次フレームへ渡す
  - window 内の token を1列に並べて scan
  - state の数は (W/w) × (H/w) 個
- 動きに合わせて window を動かす仕組みはない

shift：隣の window と混ぜる



位置に固定した state が，隣の window の情報も少しずつ受け取れるようにする

- Swin [Liu+, ICCV2021] と同じく window を 10 ずらす
  - ずらした側にも別の state H^S を持たせる
- **混ぜるのは同じフレーム内の空間方向**
  - 時間方向には合わせない
- 効果：mIoU 38.9 → 39.5
  - +0.6（Table 3，補足）

実験設定：TV3S



■ データセット

- VSPW [Miao+, CVPR2021]：124 クラス，15fps で密にアノテーション，train 2,806 / val 343 / test 387 clips
- Cityscapes [Cordts+, CVPR2016] でも評価

■ 評価指標

- mIoU：各フレームの精度
- mVC_n：**連続 n フレームで正解と一致し続ける領域の割合**（n = 8, 16）

■ 学習設定

- backbone：MiT（SegFormer [Xie+, NeurIPS2021]）など
- 全体を end-to-end で学習
- 4フレーム（t−9, t−6, t−3, t），480×480 に crop，AdamW（lr 6e−5，poly），A100 × 2
- 推論は動画全体の過去を state で持ち越す

■ 比較手法

- CFFM [Sun+, CVPR2022]
- MRCFA [Sun+, ECCV2022] など

Ablation：持ち越す過去の長さ

Number of Frames	mIoU	mVC_8	mVC_{16}
1	37.9	84.5	79.1
2	39.2	86.9	81.8
4	39.5	88.9	84.2
8	39.7	90.4	85.9
16	39.7	91.2	87.2
32	**39.7**	**91.5**	**87.8**

mVC_n：連続 n フレームで正解と一致し続ける領域の割合（ちらつきが少ないほど高い）

mIoU はすぐ飽和するが，mVC は長く持ち越すほど伸びる

■過去フレーム数を変える

- 推論時のみ，VSPW，MiT-B1
- mVC_{16}：79.1 → **87.8**（1 → 32 枚）
- mIoU：37.9 → 39.7（8 枚で飽和）

■注意

- state なしで学習し直した比較はない
- 評価条件も Table 1 と違う

定量的評価：VSPW



- MiT-B1：mIoU・mVC とも最高
  - TV3S **40.0** / 90.7 / 87.0（mIoU / mVC_8 / mVC_{16}），MRCFA 38.9 / 88.8 / 84.4
- MiT-B5：mIoU は 0.1 差で2位（49.8 vs 49.9）
  - mVC と速度（14.0 vs 5.0 FPS）は上，計算量も小さい（137.0 vs 373.0 GFLOPs）

Methods	Backbones	mIoU↑	mVC_8↑	mVC_{16}↑	GFLOPs↓	Params(M)↓	FPS↑
Segformer† [69]	MiT-B1	36.5	84.7	79.9	26.6	13.8	58.7
CFFM [57]	MiT-B1	38.5	88.6	84.1	-	15.5	29.8
MRCFA [58]	MiT-B1	38.9	88.8	84.4	-	16.2	40.1
TV3S (Ours)	MiT-B1	**40.0**	**90.7**	**87.0**	36.9	17.3	24.7
Segformer [69]	MiT-B5	48.9	87.8	83.7	185.0	82.1	9.4
CFFM [57]	MiT-B5	49.3	90.8	87.1	413.5	85.5	4.5
MRCFA [58]	MiT-B5	**49.9**	90.9	87.4	373.0	84.5	5.0
TV3S (Ours)	MiT-B5	49.8	**91.7**	**88.7**	137.0	85.6	14.0

まとめ：TV3S



- 位置に固定した state を，隣と混ぜながら持ち越す
  - 20×20 の window ごとに Mamba の state を持ち，フレーム間で持ち越す
  - 長く持ち越すほど時間方向の一貫性（mVC）が上がる
- 限界
  - mIoU は8フレームで頭打ち，shift の改善も +0.6 と小さい
  - window は位置に固定，学習（4フレーム）と推論（動画全体）で系列長が違う
  - Mamba を他の時系列モデルに替えた比較はない

次論文：動きに沿って過去を集めたら？
→ TS-Mamba（state は持ち越さず，毎フレーム集め直す）

Trajectory-aware Shifted State Space Models for Online Video Super-Resolution (TS-Mamba)

Qiang Zhu, Xiandong Meng, Yuxuan Jiang, Fan Zhang, David Bull, Shuyuan Zhu, Bing Zeng, Ronggang Wang

ICLR 2026

動きの軌跡に沿って過去を集めるオンライン動画超解像

MambaOut
前提：要るか？

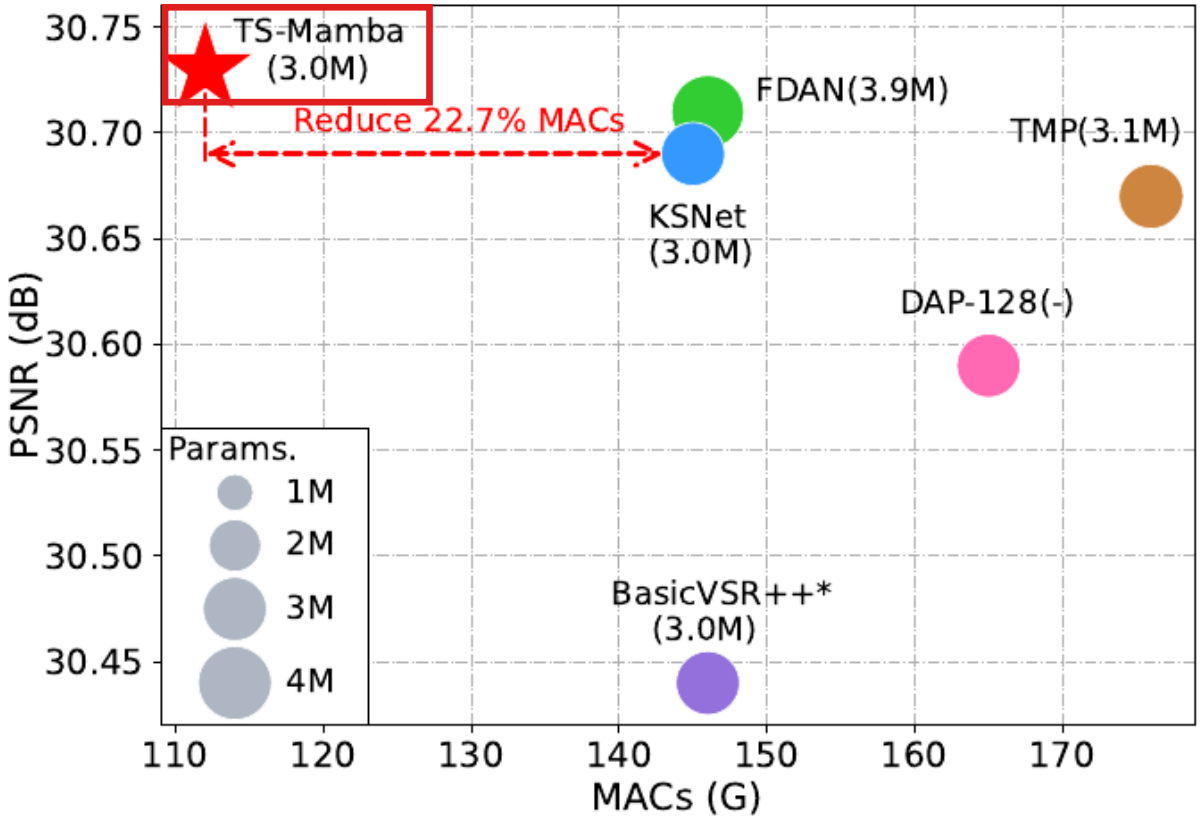
TV3S
位置に紐付けて持ち越す

TS-Mamba
軌跡に沿って集める

Memory as Dynamics
予測を信頼度で選ぶ

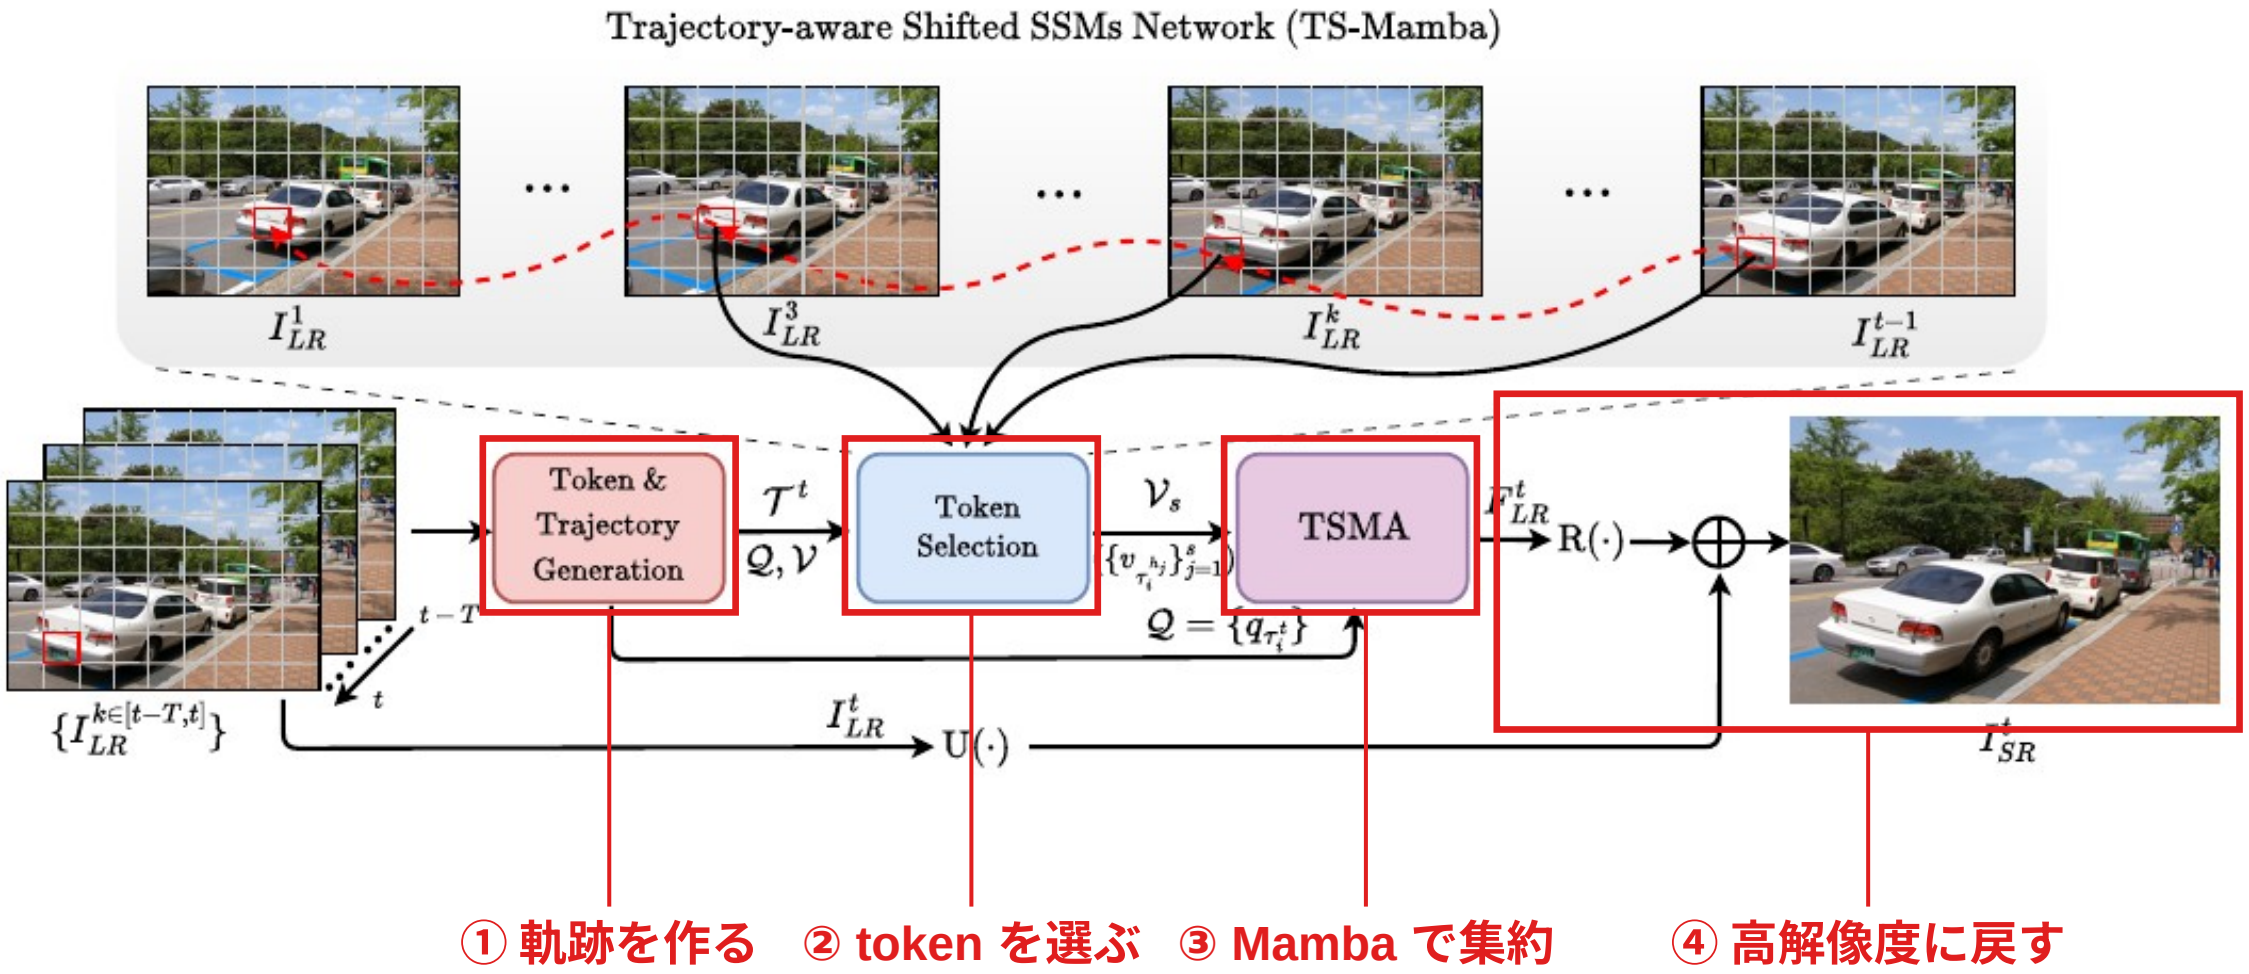
概要：軌跡に沿って過去を集める

- オンライン動画超解像（VSR）
  - 現在と**過去**のフレームだけを使う
- 従来手法の課題
  - 計算量の制約で，位置合わせに使うのは直前1フレームだけ
- 提案：TS-Mamba
  - 軌跡に沿って過去15フレームから似た token を選び，Mamba で集約



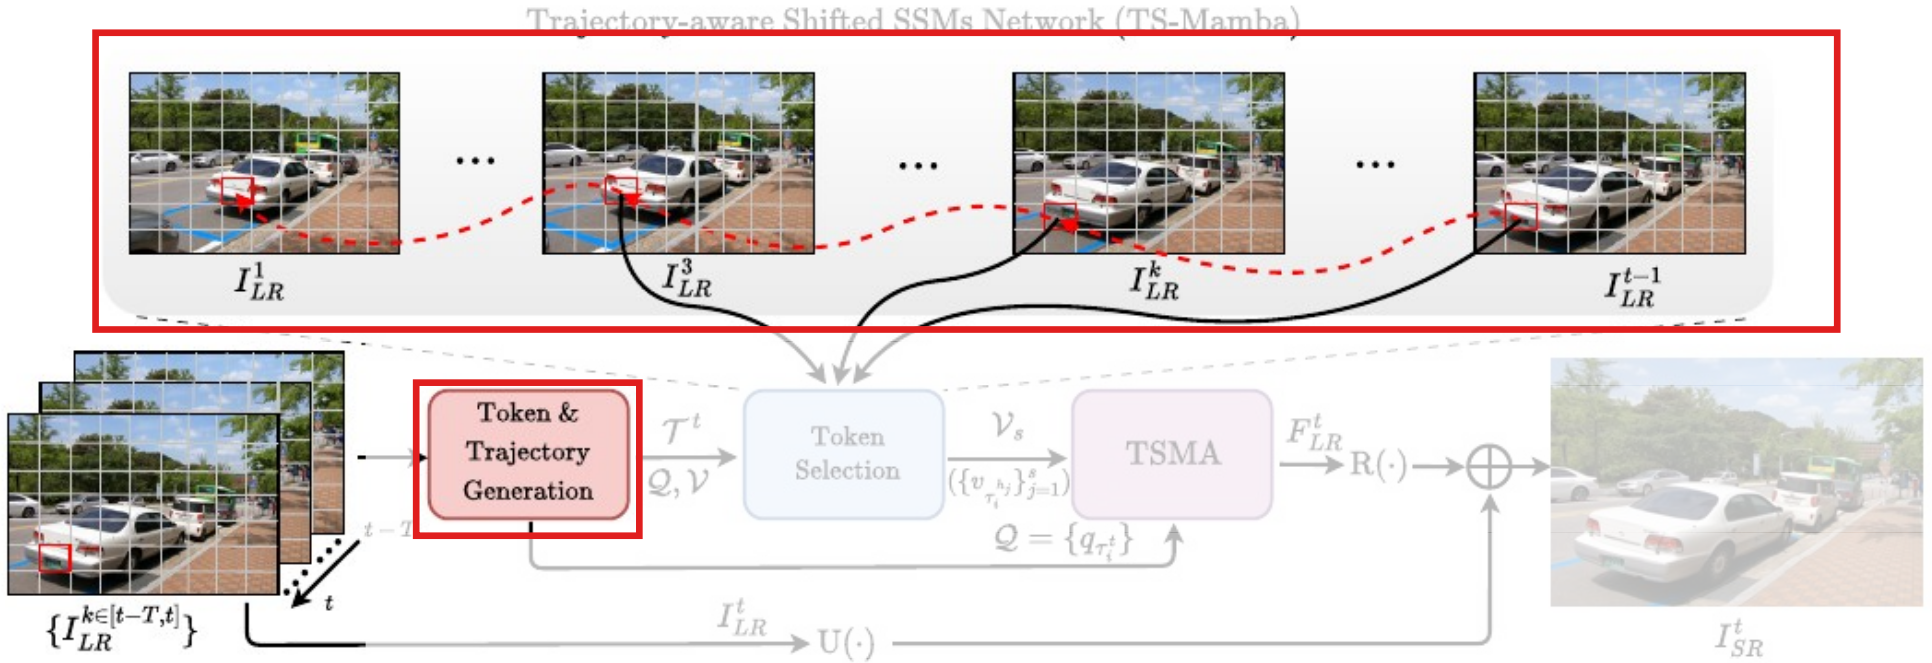
赤枠が TS-Mamba：PSNR が高く，
MACs が小さい（REDS4）

全体図：TS-Mamba


Trajectory-aware Shifted SSMs Network (TS-Mamba)
I_{LR}^{1}
I_{LR}^{3}
I_{LR}^{k}
I_{LR}^{t-1}
$\{I_{LR}^{k\in[t-T,t]}\}$
$t-T$
t
Token & Trajectory Generation
$\mathcal{T}^t$
$\mathcal{Q}, \mathcal{V}$
Token Selection
$\mathcal{V}_s$
$\{v_{\tau_i^h j}\}_{j=1}^{s}$
$\mathcal{Q} = \{q_{\tau_i^t}\}$
TSMA
$\mathcal{F}_{LR}^t$
R(·)
I_{LR}^t
U(·)
I_{SR}^t
① 軌跡を作る
② token を選ぶ
③ Mamba で集約
④ 高解像度に戻す

Step 1：軌跡を過去へたどる

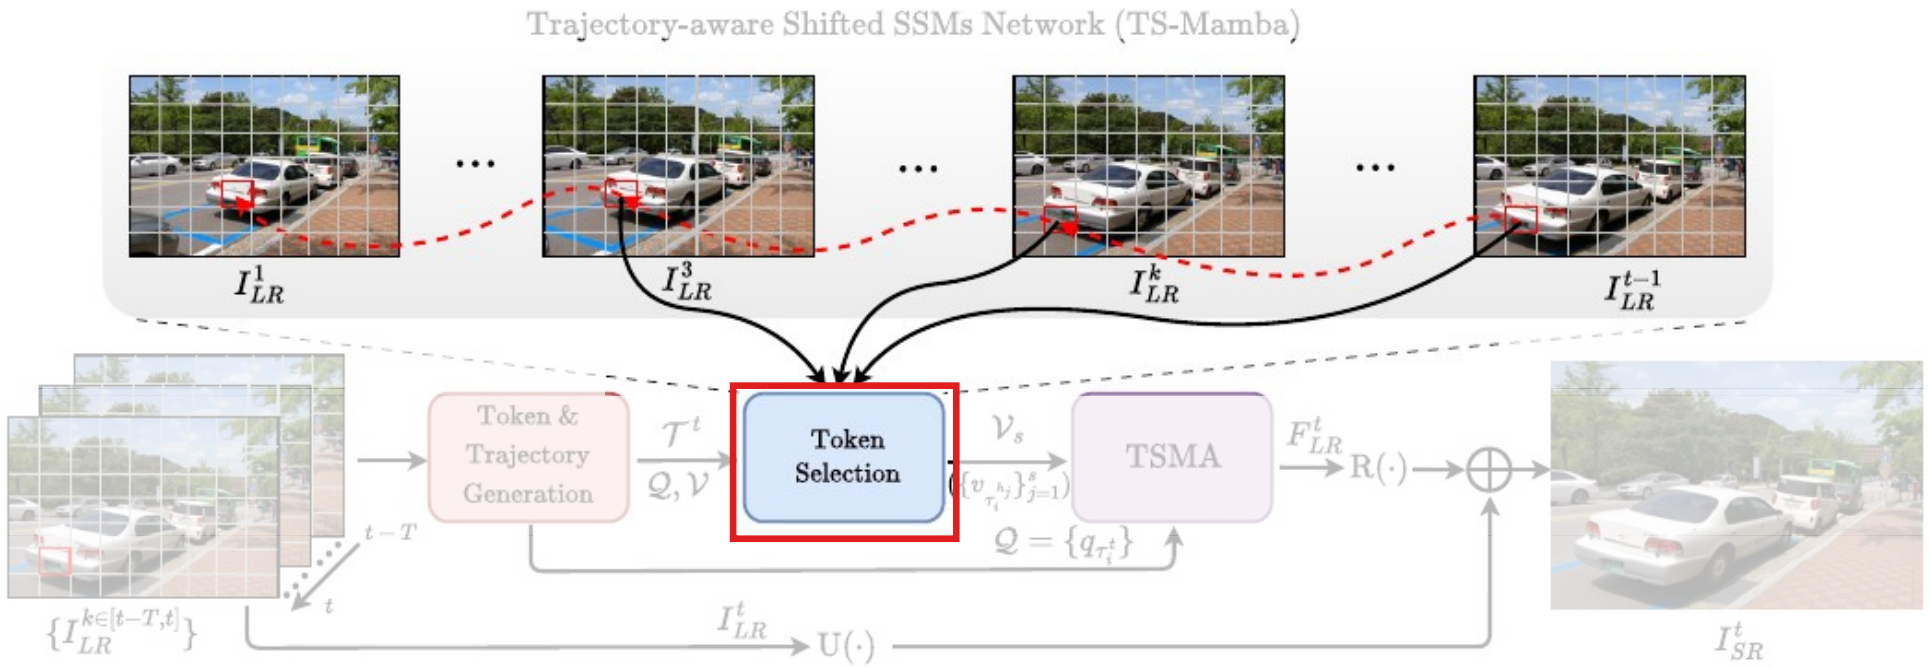
- 軌跡：現在の token が各過去フレームのどこにあったか
  - 座標の列（終点が現在の位置），過去 15 フレーム，token は 4×4 画素
- 座標は FastFlowNet [Kong+, ICRA2021] で更新
  - 作り方は TTVSR [Liu+, CVPR2022] に倣う



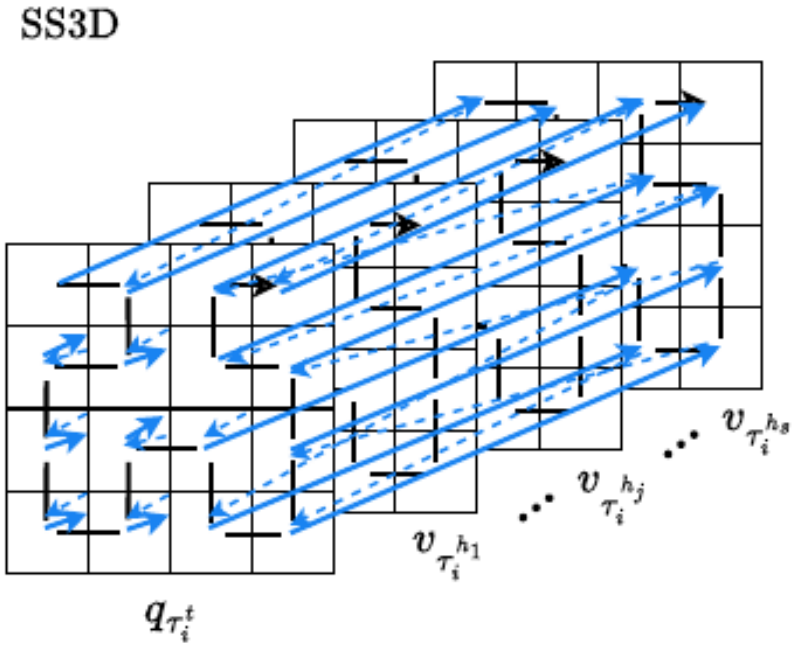
Step 2：似ている3個を選ぶ

- cosine 類似度で比べる
  - 現在の token と軌跡上の過去 token
- 上位3個の**時刻**を選ぶ
  - 空間方向の探索ではない

対応 = optical flow
使う時刻 = 類似度
と役割を分けている



Step 3：並べて Mamba で scan

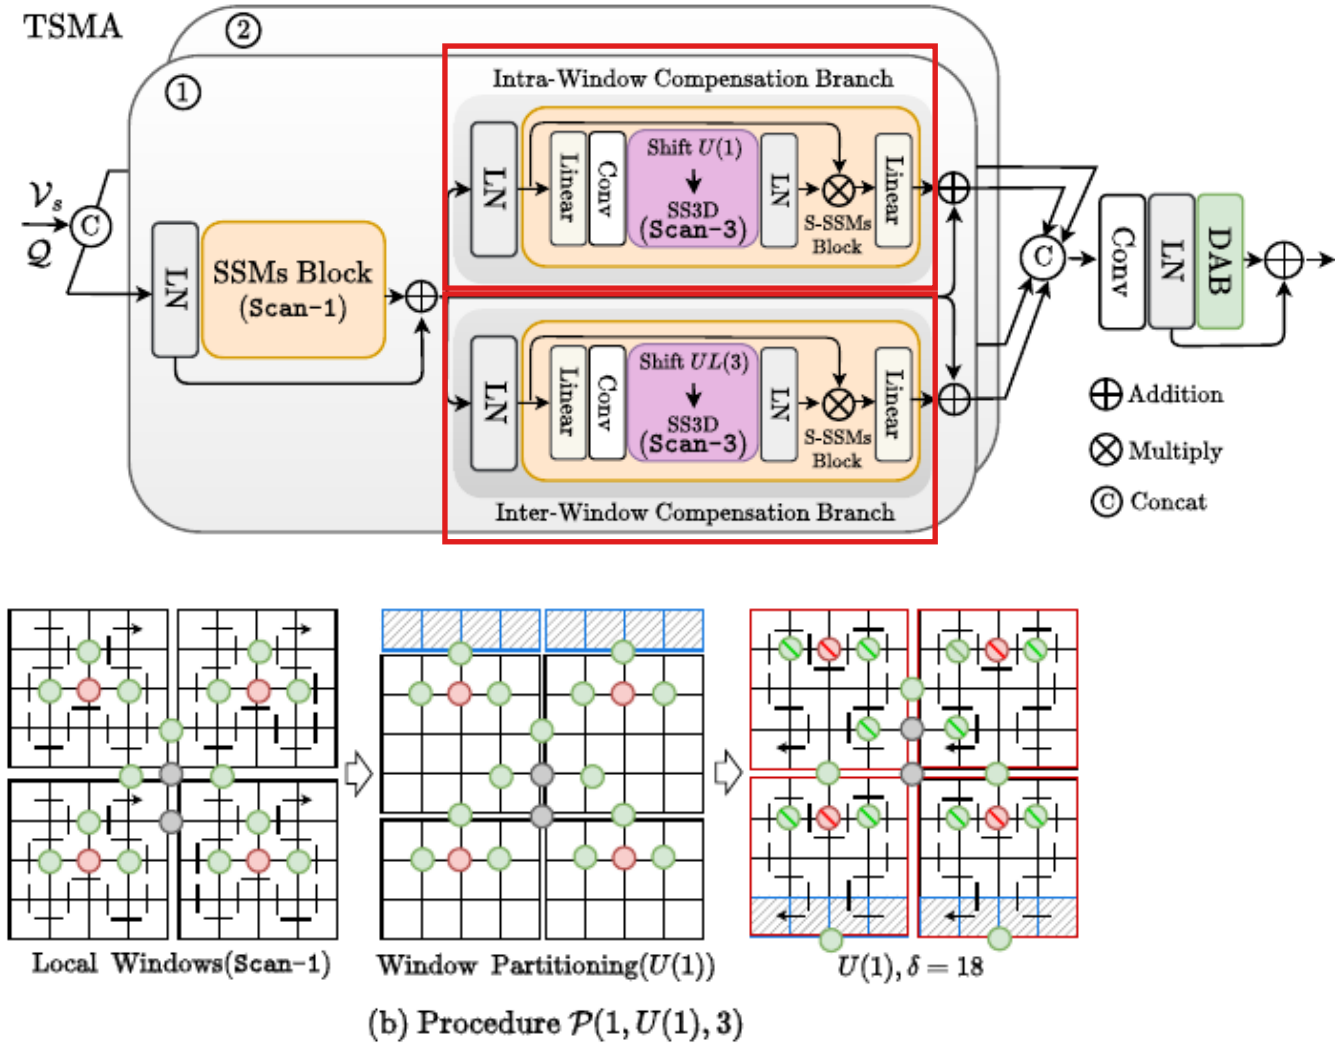


SS3D：手前が現在の token，奥が選んだ token

TV3S：state を持ち越す
TS-Mamba：過去を集めて毎回流す

- SS3D
  - 現在の token と選んだ3個を，時空間の近傍が隣り合うように1列に並べて scan
- TSMA
  - SSM block ＋ shift 版 × 2
- **持ち越す state はない**
  - 長期の情報は過去の token そのものから取る

Step 4：shift で切れた隣接を補う



- 1列にすると隣接が切れる
  - Hilbert 順でも不連続が残る
- 2回目は window をずらす
  - IntraWCB：U(1) で window 内を補う（δ = 18）
  - InterWCB：UL(3) で window 間を補う
- 両方外すと 30.52 dB
  - 30.73 dB から低下，params も 2.4M に減る

実験設定：TS-Mamba



■ データセット（×4 超解像）

- REDS [Nah+, CVPRW2019]
- Vimeo-90K [Xue+, IJCV2019]
- Vid4 [Liu+, TPAMI2014]
- 劣化：BI と BD（blur → 間引き）

■ 評価指標

- PSNR・SSIM，速度・計算量は 180×320 の LR で計測

■ 学習設定

- T = 15（REDS），token 4×4，s = 3
- Adam ＋ Cosine Annealing，HR patch 256×256，batch 8，600K iterations，RTX 3090 × 2

■ 比較手法（オンライン）

- RRN [Isobe+, BMVC2020]
- DAP [Fuoli+, WACV2023]
- FDAN [Yang+, ICIP2023]
- KSNet [Jin+, ACMMM2023]
- TMP [Zhang+, TIP2024] など

Ablation：軌跡と選ぶ数

Models	PSNR(dB)↑ / SSIM↑	Params.(M)↓	MACs(G)↓
(v1.1) *w/o* Trajectory	30.45 / 0.8678	1.7	84
(v1.2) *w/o* $\mathcal{L}_{trj}$	30.70 / 0.8721	3.0	112
TS-Mamba (ours)	30.73 / 0.8727	3.0	112

s	PSNR(dB)↑/SSIM↑	Params.↓ (M)	Run.↓ (ms)	MACs↓ (G)
1	30.64/0.8712	2.8	25	96
2	30.68/0.8720	2.9	27	104
3	30.73/0.8727	3.0	29	112
4	30.74/0.8727	3.1	31	120

- 軌跡と token 選択を外す
  - 30.73 → 30.45 dB
  - params・MACs も減る（3.0M → 1.7M，112G → 84G）
  - 軌跡と選択を別々に外した比較はない
- 軌跡の loss だけ外す
  - −0.03 dB
- 選ぶ数は3個でほぼ頭打ち
  - 4個にしても +0.01 dB

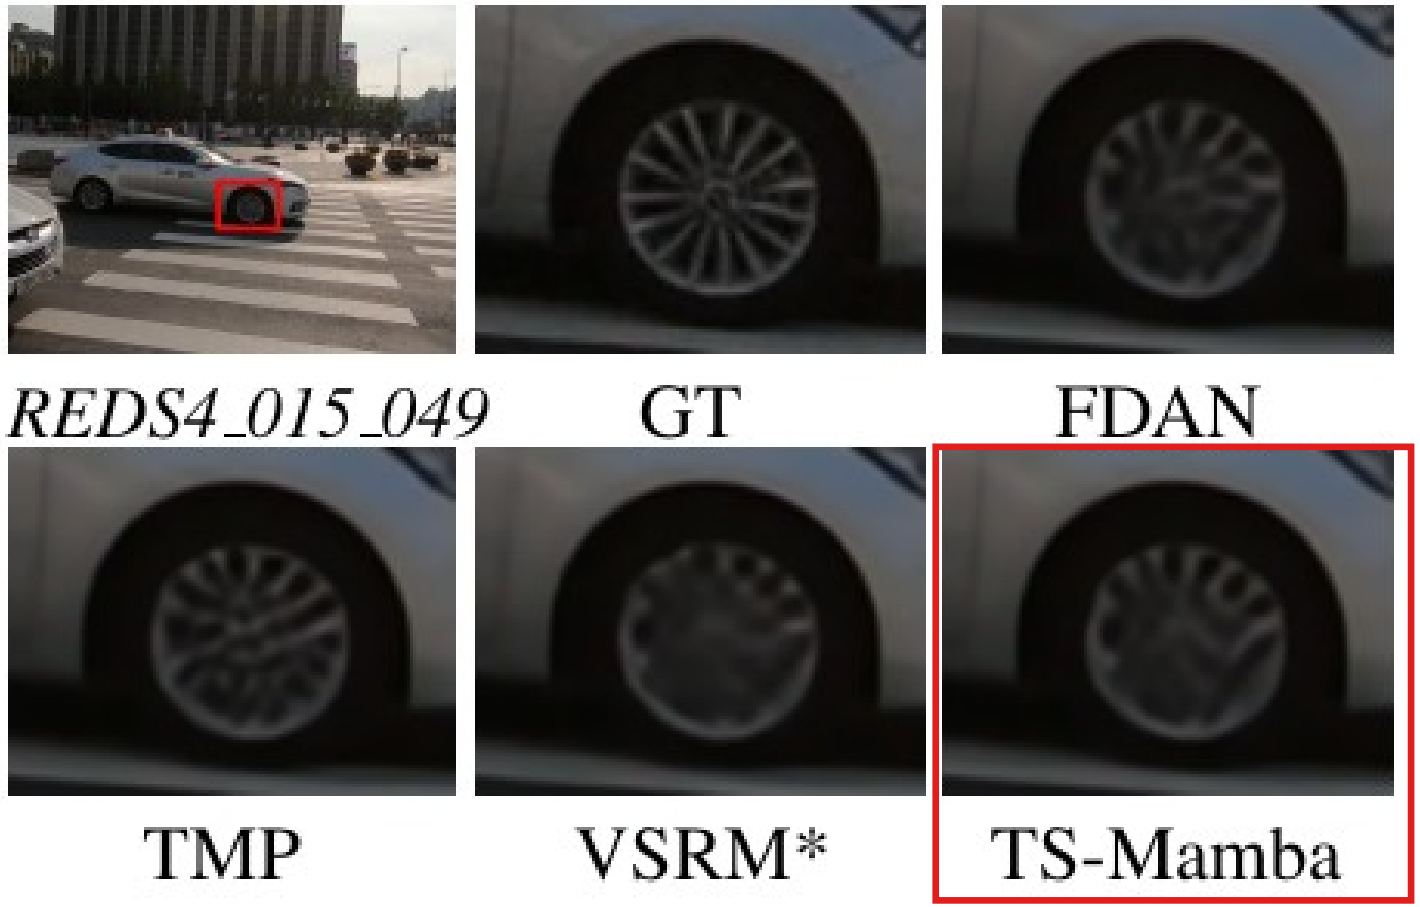
定量的評価：オンライン VSR

Table 1 からオンライン手法を抜粋（PSNR）

手法	MACs [G]	REDS4 BI [dB]	Vid4 BD [dB]
RRN	193	28.82	27.69
BasicVSR++*	146	30.44	27.49
DAP-128	165	30.59	—
FDAN	146	30.71	27.76
KSNet	145	30.69	27.63
TMP	176	30.67	27.61
VSRM*	136	30.64	27.57
TS-Mamba	112	30.73	27.70

- REDS4（BI）：**30.73** dB
  - FDAN 30.71，KSNet 30.69（差は +0.02 dB）
- MACs：112G
  - FDAN 146G，KSNet 145G
- Vid4（BD）は FDAN が上
  - 27.76 vs 27.70 dB
- 主張の中心は精度より効率

定性的評価：軌跡が崩れる場面



赤枠：TS-Mamba の出力

- 著者が挙げる失敗例
  - タイヤのような高速回転では軌跡が不正確になり，復元できない
- 外れた軌跡は除けない
  - 類似度で選ぶのは時刻だけ

まとめ：TS-Mamba



- 位置ではなく，動きの軌跡に沿って過去を集める
  - flow で軌跡をたどり，似ている3個を選んで Mamba で scan
  - state は持ち越さない
  - Mamba を替えた比較あり（付録 Table 4）：DCN などでは 30.59〜30.69 dB・132〜148G（TSMA 30.73 dB・112G）
- 限界
  - 軌跡が崩れると復元できない
  - 軌跡の効果は，計算量の変化と切り分けられていない

次論文：集めた過去や予測が外れていたら？
→ 外れたときは使わない仕組み（Memory as Dynamics）

Memory as Dynamics: Learning Reliability-Guided Predictive Models for Online Video Perception

Minwoo Kim, Sang Min Yoon

ICML 2026

SAM2 に物体の予測を足し，信頼できるときだけ使う

MambaOut
前提：要るか？

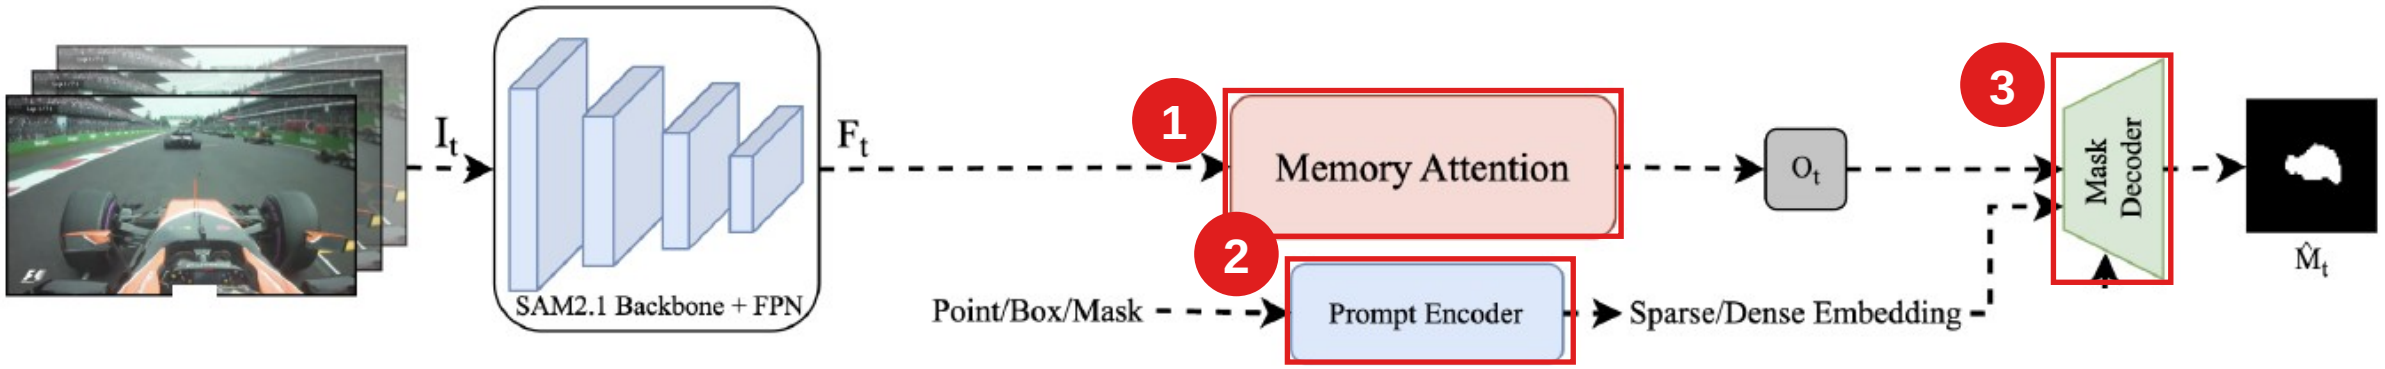
TV3S
位置に紐付けて持ち越す

TS-Mamba
軌跡に沿って集める

Memory as Dynamics
予測を信頼度で選ぶ

事前知識：SAM2

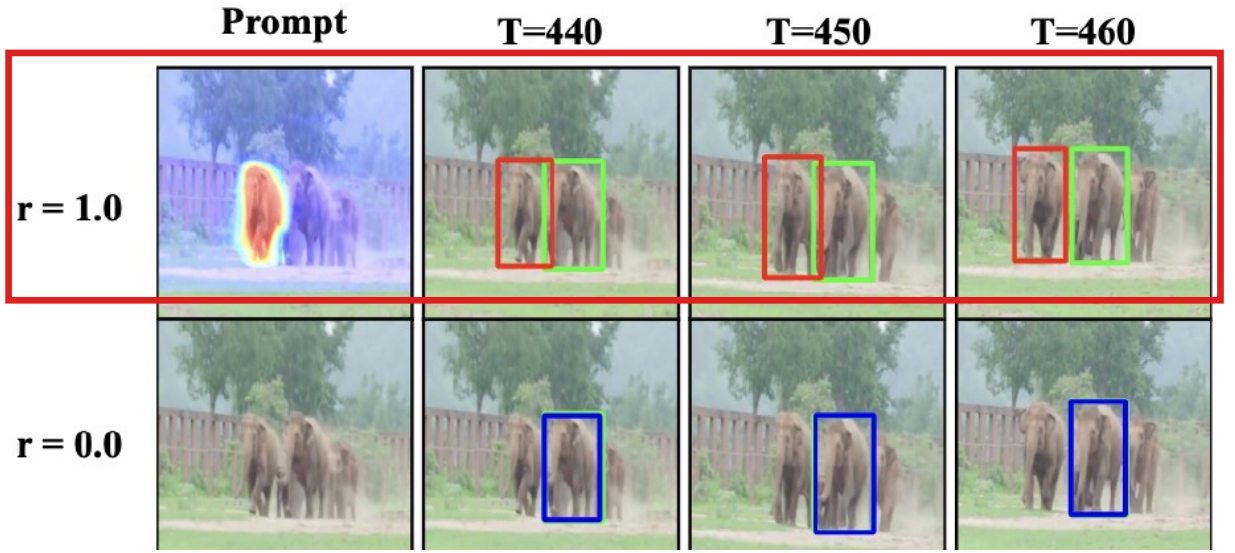
- 最初のフレームで物体を指定し，以降の mask を出す
  - ① memory attention：過去の特徴と出力をためた memory bank を参照
  - ② prompt encoder：点・box・mask の指示
  - ③ mask decoder：mask と予測 IoU（自己評価）
- 出力は memory bank に入る → **誤った出力も入る**



SAM 2 [Ravi+, ICLR2025]

問題：予測を混ぜると drift

- SAM2 の memory は遮蔽・速い動きに弱い
  - → 未来を予測する memory を足したい
- 予測を無条件に入れると
  - 遮蔽中の誤った予測が memory に入り，**回復できない drift**
  - 著者：reliability mismatch（信頼できない予測を観測と同等に扱う）



r = 1.0：予測を混ぜ続ける → 赤枠（追跡結果）が隣の象へ

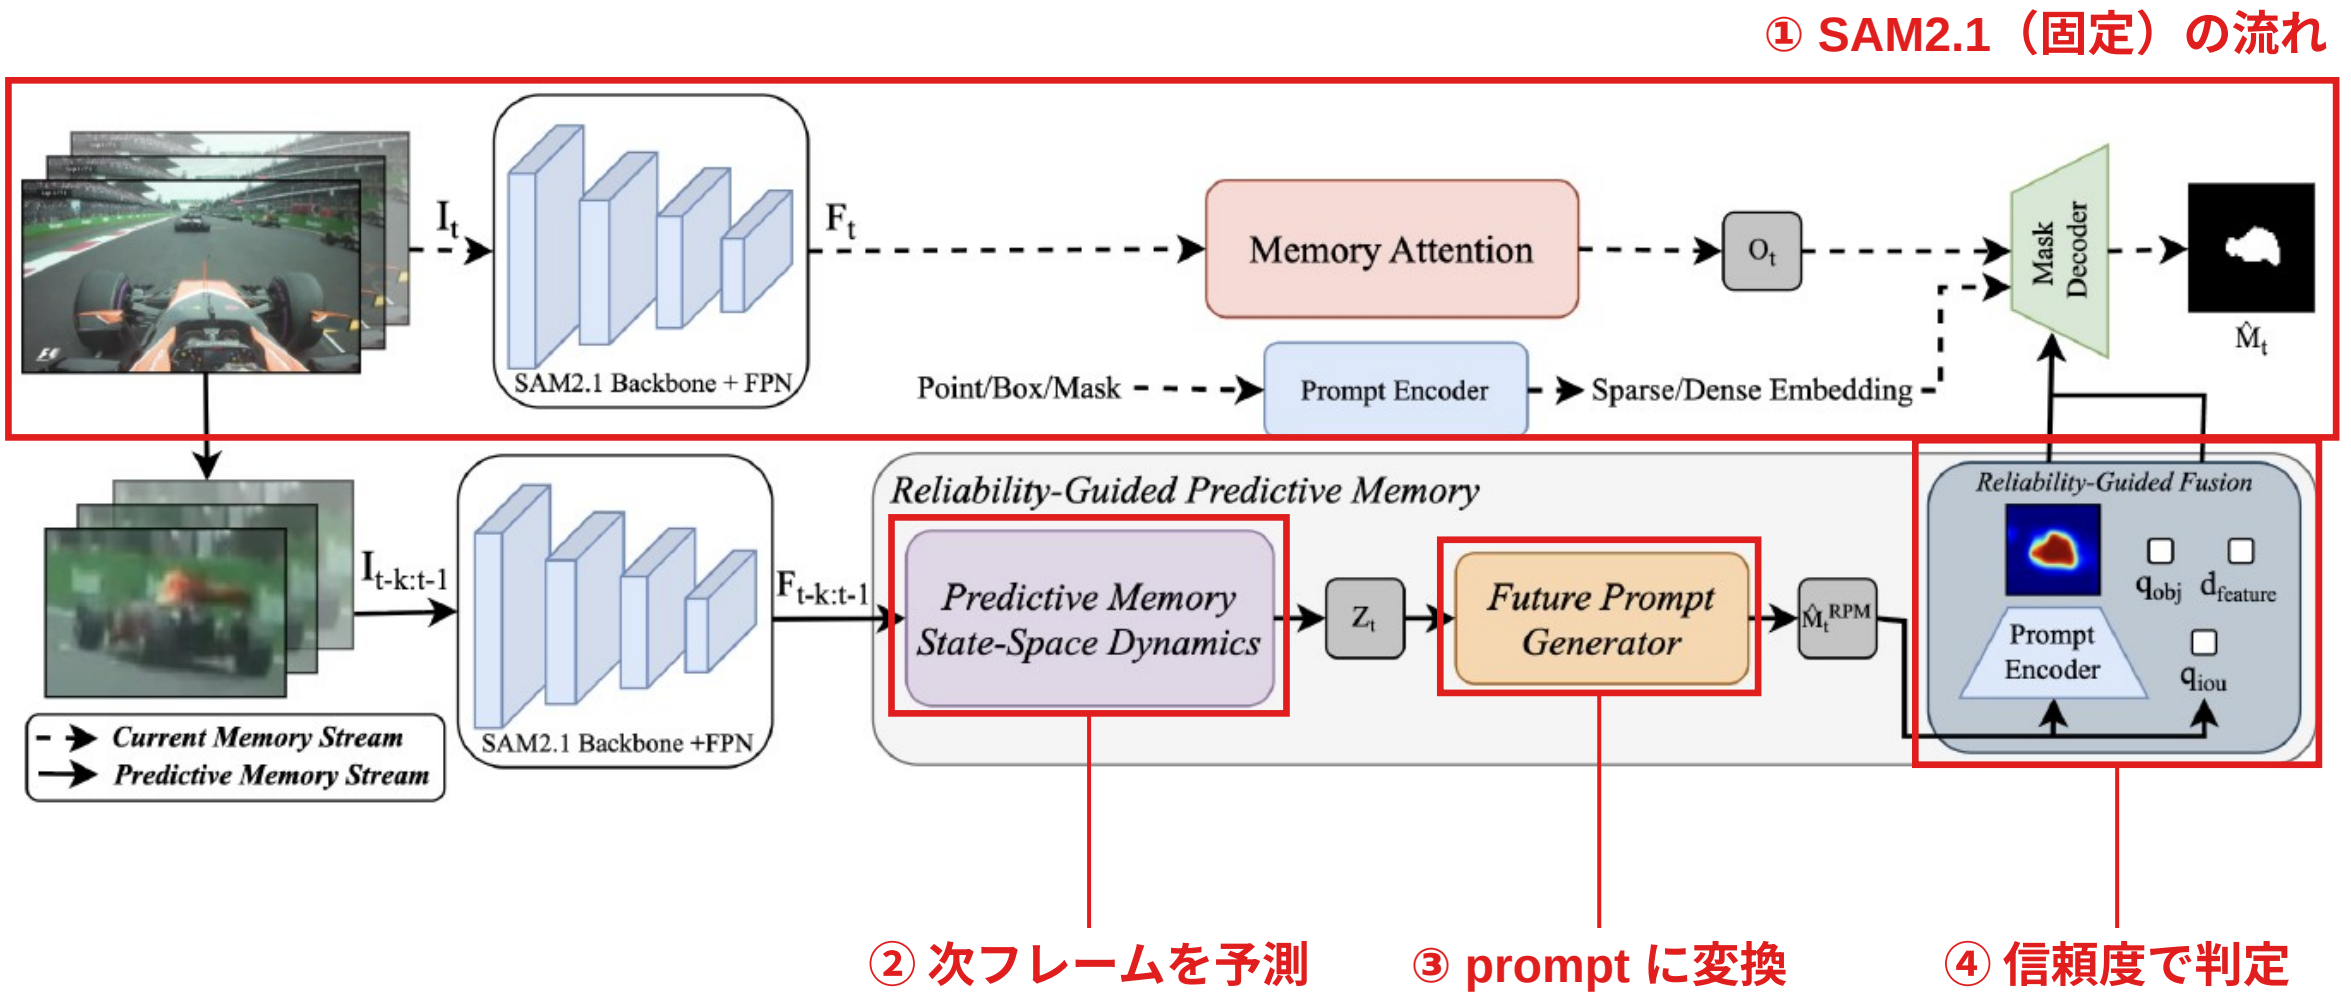
r = 0.0：予測なし → 青枠（正しい追跡），緑枠：正解

概要：信頼できるときだけ予測を使う

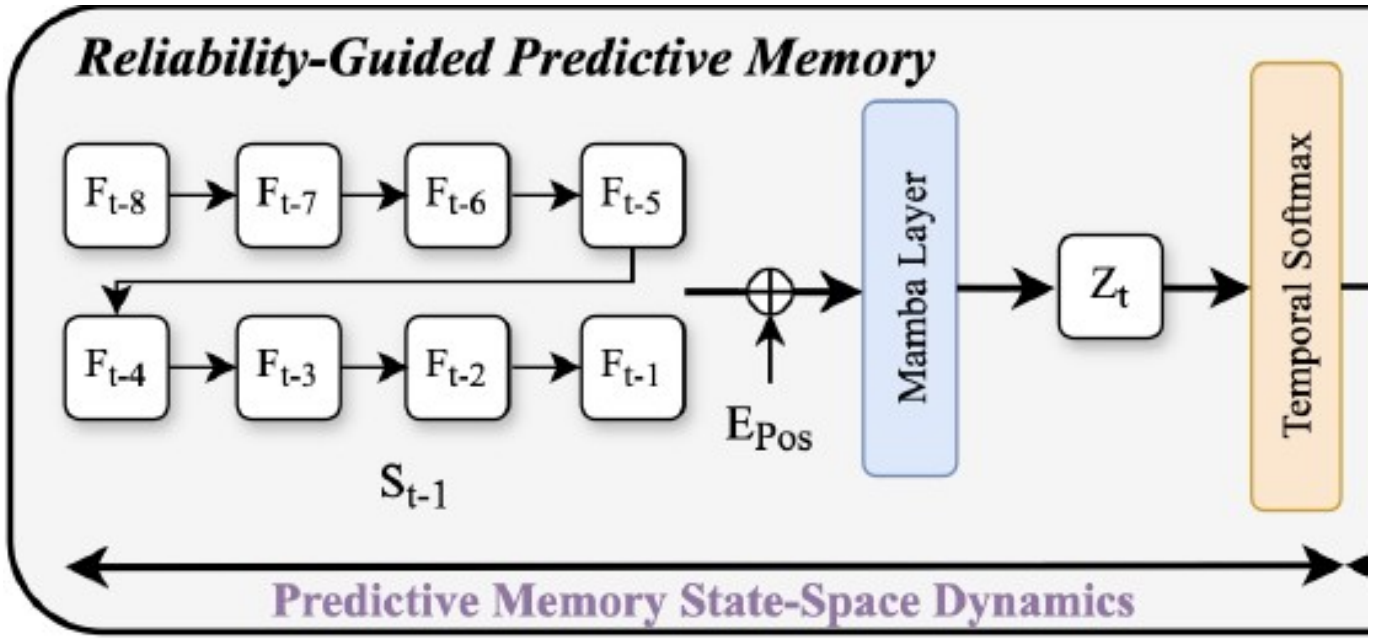


- 提案：Reliability-Guided Predictive Memory（RPM）
  - 直近8フレームの特徴から，Mamba2 で次フレームの特徴を予測
  - 観測の信頼度が低く，かつ予測が観測と矛盾しないときだけ使う
  - 予測は memory に直接は書き込まず，dense prompt として decoder に足す
  - ただし予測を使ったフレームでは，その出力が memory に入る
- 前提
  - SAM2.1-B（**完全に固定**）＋ HiM2SAM [Chen+, PRCV2025] の memory 更新方式の上に作る（全実験で共通）

全体図：Memory as Dynamics



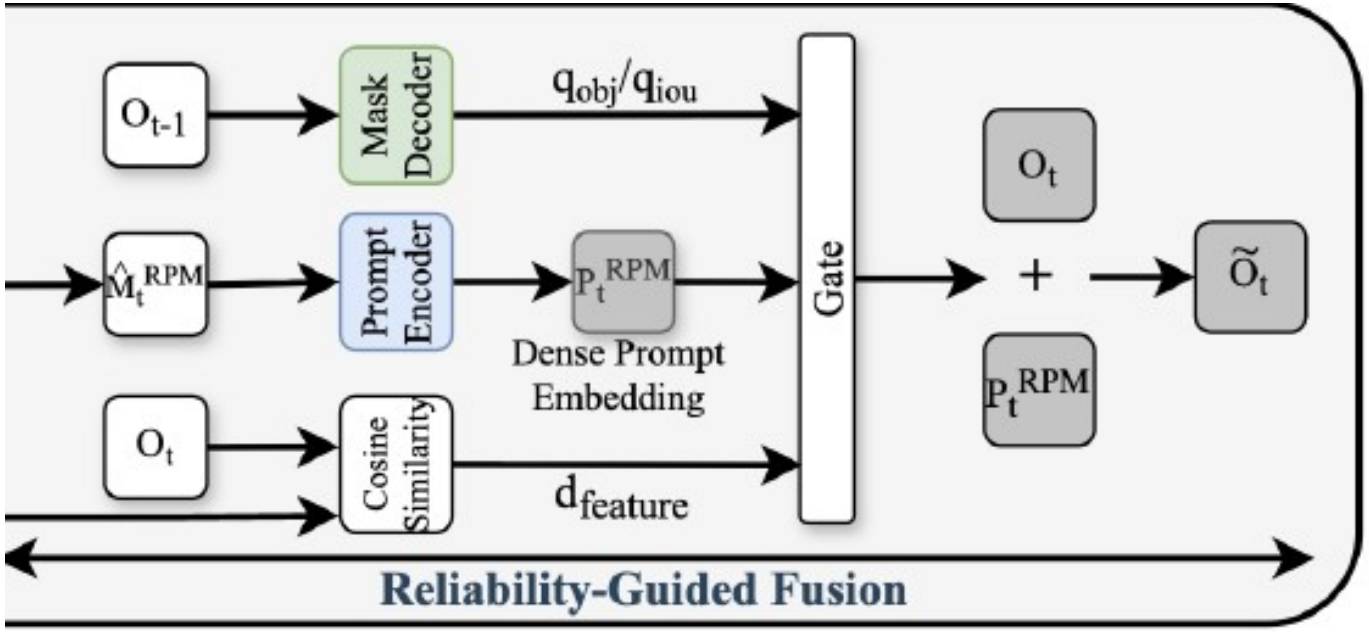
予測：直近8フレーム → 次



TS-Mamba と同じく，SSM は短い系列に使い，
長期の情報は別の memory に置く

- 入力：直近8フレームの特徴
  - 時刻の埋め込みを足す
- Mamba2 [Dao+, ICML2024]（24層）で scan → 1フレーム先を予測
- **state は窓の中だけ**
  - 8フレームの窓を毎時刻作り直す
  - 長く持ち越すのは SAM2 の memory bank

信頼度：使うかを 0/1 で決める



止めるのは「予測の使用」
Mamba の state 更新を止めるのではない

- 2段階の判定
  - ① 前の予測 IoU < 0.4 → 予測を計算
  - ② 観測との cosine 距離 < 0.3 → 使う
- 使うときだけ足す
  - $\tilde{o}_t = o_t + \rho_t \cdot p_t$（$\rho_t \in \{0, 1\}$）
- 学習しない固定ルール
  - 使った割合：**3.71%**（LaSOT）

実験設定：Memory as Dynamics



- 学習（RPM のみ）
  - SA-V [Ravi+, ICLR2025]
  - MOSE [Ding+, ICCV2023]
  - YouTube-VOS [Xu+, ECCV2018]
  - AdamW（lr 1×10^{-4}），batch 1，8 フレーム，50 epochs
- 比較手法（SAM2 系）
  - SAMURAI [Yang+, arXiv2024]
  - DAM4SAM [Videnovic+, CVPR2025]
  - HiM2SAM [Chen+, PRCV2025]
- 評価（SOT は zero-shot）
  - LaSOT [Fan+, CVPR2019]
  - $\text{LaSOT}_{\text{ext}}$ [Fan+, IJCV2021]
  - GOT-10k [Huang+, TPAMI2021]
  - AUC・P_{norm}・P（GOT-10k は AO・SR）
- 評価（VOS）
  - LVOS [Hong+, ICCV2023] など7種の J&F
- 速度：A100 1枚での推論時間

定量的評価：zero-shot トラッキング



- zero-shot の SAM2 系で最高
  - SAM2.1-B から LaSOT AUC 66.0 → **74.5**，$\text{LaSOT}_{\text{ext}}$ 55.5 → 60.9
- RPM の上乗せは HiM2SAM-B との差
  - 73.4 → 74.5，59.3 → 60.9（memory 更新は HiM2SAM が下敷き）
- 補足
  - 追加部分は VOS データで学習（81M → 93M），VOS の J&F も向上（SA-V test 77.7 → 79.8）

Trackers	Source	#Param (M)	GOT-10k			LaSOT			LaSOT_{ext}		
			AO	$\text{SR}_{0.5}$	$\text{SR}_{0.75}$	AUC	P_{norm}	P	AUC	P_{norm}	P
SAMURAI-B (Yang et al., 2024)	arXiv'24	81	79.6	**90.8**	72.9	70.7	78.7	76.2	57.5	69.3	67.1
SAM2.1-B (Ravi et al., 2025)	ICLR'25	81	77.9	88.6	71.5	66.0	73.5	71.0	55.5	67.2	64.6
DAM4SAM-B (Videnovic et al., 2025)	CVPR'25	81	78.1	88.5	70.9	73.3	81.3	78.8	58.6	69.4	68.2
HiM2SAM-B (Chen et al., 2025a)	PRCV'25	81	78.1	88.9	71.7	73.4	81.7	79.5	59.3	71.2	69.4
Ours-B	ICML'26	93	**79.7**	90.6	72.9	74.5	82.9	80.7	**60.9**	**73.1**	**71.4**

Ablation：予測の混ぜ方

Method	AUC
SAM2.1-B	66.0
Always-on Prediction Injection	70.5
Soft-Gating (Learned Scalar)	72.3
Reliability-Guided Binary Gating	**74.5**

参考：予測なしの HiM2SAM-B は 73.4（同構成かは不明）

Trackers	Short(<5)	Medium(5–20)	Long(>20)
SAMURAI	0.498	0.421	0.311
HiM2SAM	0.552	0.482	0.384
Ours	**0.577**	**0.517**	**0.421**

- 混ぜ方の比較（LaSOT AUC）
  - 毎フレーム足す：70.5
  - 学習した重みで少しずつ（soft）：72.3
  - 信頼度で 0/1 に切り替える：**74.5**
- 遮蔽が長いほど差が開く
  - 20フレーム超の遮蔽の後5フレームの IoU：HiM2SAM 0.384 → 0.421

まとめ：Memory as Dynamics



- 長期の memory は SAM2 に任せ，予測は信頼できるときだけ使う
  - 直近8フレームから Mamba2 で次フレームを予測し，prompt として足す
  - 使うかどうかを 0/1 で切り替える方が，少しずつ混ぜるより良い（LaSOT，74.5 vs 72.3）
- 限界・注意
  - RPM 単体の効果が分離されていない（HiM2SAM の memory 更新が下敷き）
  - 信頼度の効果の大半は予測 IoU 単独（70.5 → 73.8）
  - Mamba を他の時系列モデルに替えた比較はない
  - 複数物体の扱いは書かれていない

本紹介のまとめ（1/2）



前提（MambaOut）：SSM の state は固定サイズで lossy，長く causal な系列で使う

論文	紐付け先	SSM が scan する系列	長く持ち越すもの	信じる仕組み
TV3S（動画の領域分割）	位置（20×20 window）	window 内の token と過去フレーム	window ごとの SSM state	明示的な仕組みなし
TS-Mamba（動画超解像）	軌跡（optical flow）	軌跡上の現在＋過去3 token	過去15フレームの token と軌跡	類似度で使う時刻を選ぶ
Memory as Dynamics（SOT / VOS）	物体（SAM2 の追跡対象）	直近8フレーム分の特徴	SAM2 の memory bank	予測を 0/1 で切り替える

本紹介のまとめ（2/2）



- 3本はタスクが違うので，優劣は比べられない
- SSM の state を長く持ち越すのは TV3S だけ
  - TS-Mamba・MaD：長期の情報は別の memory，SSM は短い系列
- 信じ方：MaD（LaSOT）では，予測を 0/1 で切り替える方が少しずつ混ぜるより良かった
  - 他の条件では未検証
- Mamba を替えた比較があるのは TS-Mamba だけ
  - DCN などより +0.04〜0.14 dB，MACs も少ない（付録 Table 4）

補足

補足：TV3S の推論



Algorithm 1 Inference Procedure for TV3S Architecture

1: **Input:** Frame sequence $\{\boldsymbol{I}_t\}$
2: **Output:** Segmentation map $\boldsymbol{O}_t$
3: **Initialize:** Hidden states $\boldsymbol{H}$ for all TV3S blocks
4: **for** each frame $\boldsymbol{I}_t$ in the sequence **do**
5: $\quad \boldsymbol{E}_t \leftarrow \text{Encoder}(\boldsymbol{I}_t)$ // Extract features
6: $\quad$ **for** each patch (i, j) in $\boldsymbol{E}_t$ **do**
7: $\quad\quad \hat{\boldsymbol{P}}^{i,j} \leftarrow \text{Flatten}(\boldsymbol{E}_t[i : i + w, j : j + w, :])$
8: $\quad\quad$ **for** each TV3S block n from 1 to N **do**
9: $\quad\quad\quad$ //Update Features and Hidden State.
10: $\quad\quad\quad \boldsymbol{F}_t^{n,i,j}, \boldsymbol{H}_t^{n,i,j} \leftarrow \text{TV3S}^n(\hat{\boldsymbol{P}}^{i,j}, \boldsymbol{H}^{n,i,j})$
11: $\quad\quad$ **end for**
12: $\quad$ **end for**
13: $\quad \boldsymbol{O}_t \leftarrow \text{Interpolate}(\text{Linear}(\boldsymbol{F}_t^N))$ // Segmentation
14: $\quad \boldsymbol{H} \leftarrow \{\boldsymbol{H}_t\}$ // Store for next frame
15: **end for**

- Algorithm 1（推論）
  - 10行目：window ごとに state を更新
  - 14行目：更新した state を次のフレームのために保存
- 動画全体の過去を state で使う
- 学習は4フレーム
  - t−9, t−6, t−3, t
  - 学習と推論で系列長が違う点は未検証（発表者の所見）

補足：TV3S の shift の効果

Models	Evaluation (mIoU)		
	Add	Concat	Direct
1 TSS (No Shift)	37.6	37.8	38.0
TV3S (No Shift)	38.1	38.4	38.9
TV3S (Shift)	**38.5**	**39.3**	**39.5**

位置に固定した state でも，
隣と混ぜれば少し良くなる（+0.6）

- Table 3（MiT-B1）
  - 1 TSS（shift なし）：38.0
  - TV3S（shift なし）：38.9
  - TV3S（shift あり）：**39.5**
- 3行とも state は持ち越す
  - 比べているのは shift の有無と出力のつなぎ方

補足：TV3S の VSPW 全結果



Methods	Backbones	mIoU↑	mVC_8↑	mVC_{16}↑	GFLOPs↓	Params(M)↓	FPS↑
Segformer† [69]	MiT-B1	36.5	84.7	79.9	26.6	13.8	58.7
CFFM [57]	MiT-B1	38.5	88.6	84.1	-	15.5	29.8
MRCFA [58]	MiT-B1	38.9	88.8	84.4	-	16.2	40.1
TV3S (Ours)	MiT-B1	**40.0**	**90.7**	**87.0**	36.9	17.3	24.7
Segformer [69]	MiT-B2	43.9	86.0	81.2	100.8	24.8	16.2
CFFM [57]	MiT-B2	44.9	89.8	85.8	143.2	26.5	10.1
MRCFA [58]	MiT-B2	45.3	90.3	86.2	127.9	27.3	10.7
TV3S (Ours)	MiT-B2	**46.3**	**91.5**	**88.35**	53.9	28.3	21.9
Mask2Former† [7]	R50	38.5	81.3	76.4	110.6	44.0	19.4
MPVSS [67]	R50	37.5	84.1	77.2	38.9	84.1	33.9
Mask2Former† [7]	R101	39.3	82.5	77.6	141.3	63.0	16.9
MPVSS [67]	R101	38.8	84.8	79.6	45.1	103.1	32.3
DeepLabv3+† [6]	R101	34.7	83.2	78.2	379.0	62.7	9.2
UperNet† [68]	R101	36.5	82.6	76.1	403.6	83.2	16.0
PSPNet† [72]	R101	36.5	84.2	79.6	401.8	70.5	13.8
OCRNet† [71]	R101	36.7	84.0	79.0	361.7	58.1	14.3
TCB† [42]	R101	37.8	87.9	84.0	1692	-	-
ETC† [37]	OCRNet	37.5	84.1	79.1	361.7	-	-
Segformer [69]	MiT-B5	48.9	87.8	83.7	185.0	82.1	9.4
CFFM [57]	MiT-B5	49.3	90.8	87.1	413.5	85.5	4.5
MRCFA [58]	MiT-B5	**49.9**	90.9	87.4	373.0	84.5	5.0
TV3S (Ours)	MiT-B5	49.8	**91.7**	**88.7**	137.0	85.6	14.0
Mask2Former† [7]	Swin-T	41.2	84.5	80.0	114.4	47.4	17.1
MPVSS [67]	Swin-T	39.9	85.9	80.4	39.7	114.0	32.8
TV3S (Ours)	Swin-T	**44.9**	**88.0**	**83.5**	57.3	31.7	22.9
Mask2Former† [7]	Swin-S	42.1	84.7	79.3	152.2	68.9	14.5
MPVSS [67]	Swin-S	40.4	86.0	80.7	47.3	108.0	30.6
TV3S (Ours)	Swin-S	**50.6**	**89.6**	**85.8**	94.1	53.1	19.5

補足：TS-Mamba の全比較

Category	Methods	Supp. Frame	R-T	Run.↓ (ms)	FPS↑ (1/s)	MACs↓ (G)	Params.↓ (M)	BI degradation REDS4(RGB)↑ (PSNR/SSIM)	BI degradation Vid4(Y)↑ (PSNR/SSIM)	BD degradation Vimeo-90K-T(Y)↑ (PSNR/SSIM)	BD degradation Vid4(Y)↑ (PSNR/SSIM)
Bidirectional	BasicVSR	P+F	✗	63	15.9	397	6.3	31.42/0.8909	27.24/0.8251	37.53/0.9498	27.96/0.8553
	IconVSR	P+F	✗	70	14.3	452	8.7	31.67/0.8948	27.39/0.8279	37.84/0.9524	28.04/0.8570
	BasicVSR++	P+F	✗	77	13.0	418	7.3	32.39/0.9069	27.79/0.8400	38.21/0.9550	29.04/0.8753
	SSL-bi	P+F	✗	24	41.7	92	1.0	31.06/0.8933	27.15/0.8208	37.06/0.9458	27.56/0.8431
	DFVSR	P+F	✗	-	-	-	7.1	32.76/0.9081	27.92/0.8427	38.51/0.9571	29.56/0.8983
	MIA-VSR	P+F	✗	318	3.1	3220	16.5	32.78/0.9220	28.20/0.8507	-	-
	IART	P+F	✗	180	5.6	5020	13.4	32.90/0.9138	28.26/0.8517	38.62/0.9579	29.68/0.8884
	VSRM	P+F	✗	223	4.5	2174	17.1	33.11/0.9162	28.44/0.8552	-	-
Online	Bicubic	N	✓	-	-	-	-	26.14/0.7292	23.78/0.6347	31.30/0.8687	21.80/0.5246
	RRN	P	✓	34	29.4	193	3.4	28.82/0.8234	25.85/0.7660	36.69/0.9432	27.69/**0.8488**
	BasicVSR++*	P	✓	40	25.0	146	**3.0**	30.44/0.8686	27.06/0.8173	37.11/0.9464	27.49/0.8426
	DAP-128	P	✓	38	26.3	165	-	30.59/0.8703	-	37.29/0.9476	-
	FDAN	P	✓	34	29.4	146	3.9	30.71/0.8723	27.14/0.8206†	**37.36**/0.9483†	**27.76**/0.8471
	KSNet	P	✓	31	32.3	145	**3.0**	30.69/0.8724	27.14/0.8208	37.34/**0.9490**	27.63/0.8444†
	TMP	P	✓	**25**	**40.1**	176	3.1	30.67/0.8710	27.10/0.8167	37.33/0.9481	27.61/0.8428
	VSRM*	P	✓	31	32.7	136	3.1	30.64/0.8701	27.10/0.8163	37.28/0.9477	27.57/0.8423
	TS-Mamba	P	✓	29	33.5	**112**	**3.0**	**30.73/0.8727**	**27.17/0.8209**	**37.36**/0.9482	27.70/0.8473

補足：MaD の信頼度の内訳

q_{iou}	q_{obj}	d_{feature}	AUC	P_{norm}	P
×	×	×	70.5	78.7	76.6
✓	×	×	73.8	82.0	79.8
✓	✓	×	73.9	82.1	79.9
✓	×	✓	74.0	82.2	80.1
✓	✓	✓	**74.5**	**82.9**	**80.7**

- 予測 IoU だけで 70.5 → 73.8
  - 上がり幅の大半
- 3つすべてで 74.5
- q_{obj} は予測を置く位置の判定用

予測を使ったフレームの割合：LaSOT 3.71%，LaSOT_{ext} 4.89%

Dataset	Target Unobservability (%)		Low-Confidence Observation (%)	Activation Rate (%)
	Full-Occlusion	Out-of-View		
LaSOT	1.14	1.54	1.03	3.71
LaSOT_{ext}	3.23	0.28	1.38	4.89

補足：MambaOut の「長い系列」



- Transformer block の FLOPs = $24D^2L + 4DL^2$（Eq. 6）
  - L の2乗の項が1次の項を超えるのは $L > 6D$ のとき（Eq. 7）
  - ViT-S（D = 384）：2304　／　ViT-B（D = 768）：4608
- ImageNet（224^2，patch 16^2）：196 token → 長くない
- COCO・ADE20K：約 4K token → 長い
  - 入力 800 × 1280（COCO），512 × 2048（ADE20K）