

SAM2 / SAMURAI × Mamba 系 SSM

Mask Decoder ・ Memory ・ Tracking への導入戦略

Deep Research Report — 2023-2026 年 9 月の Vision Mamba 潮流と研究方針

目的：単純な Transformer→Mamba 置換ではなく、SAM2/SAMURAI 固有の prompt ・ mask ・ motion ・ memory 構造を利用した、技術的必然性と新規性の両立を検討する。

最重要結論

本命は「Two-Way Transformer の全面置換」ではない。Mask Decoder では prompt→image cross-attention を保持し、dense image stream を non-causal / local-global Mamba で補強する方向が妥当。一方、Mamba の“state を持ち越す”性質を最も素直に活かせるのは、SAM2 の object pointer history や長期 memory を causal SSM state へ拡張する方向である。SAMURAI の previous mask / Kalman prior を scan ・ gating ・ state update に使えば、単なる bbox trajectory 予測とは異なる、SAM2 固有の新規性を作りやすい。

1. Executive Summary

2024-2026 年の主要 Vision Mamba 研究を追うと、vanilla な 1D causal Mamba を画像へそのまま適用する方向は急速に中心から外れ、bidirectional、SS2D、多方向 scan、local/window、local-global、non-causal SSD、deformable/dynamic scan、Attention hybrid へと設計が分化している。Vim/VMamba/LocalMamba/QuadMamba から、VSSD ・ MambaVision ・ DefMamba ・ PVMamba ・ DAMamba、さらに 2026 年の TMambaDet や MS-Temba へ続く流れは、この傾向を明確に示す [R1-R14, R34-R36]。ただしこれは厳密な bibliometric majority の主張ではなく、主要な高インパクト設計の質的傾向である。

SAM2 の Mask Decoder にある Two-Way Transformer は、dense image token 同士を全面的に mix するための通常の ViT block ではない。sparse prompt/output token の self-attention、token→image cross-attention、token MLP、image→token cross-attention を交互に行うことで、prompt-conditioned mask decoding を成立させている [R37, R38]。したがってこれを丸ごと Mamba へ置換すると、Mamba の利点を得る前に SAM 固有の prompt-image alignment を失う危険が高い。

Mask Decoder を研究主軸にするなら、cross-attention は残し、dense image feature 側へ non-causal 2D Mamba/SSD を residual mixer として挿入するのが最も安全な第一歩である。その上で target 周辺 Local Mamba+低解像度 Global Mamba、previous mask/Kalman bbox/uncertainty による routing ・ scan weighting を導入すると、近年の Vision Mamba 潮流と SAMURAI 固有情報の双方を使える。

Mamba の技術的必然性だけを見ると、Mask Decoder より object pointer / temporal memory の方が強い。MambaLCT、MambaVLT、SMTrack は、時間方向の長い履歴を hidden state で継続的に集約する用途で Mamba を使い、Attention を appearance/query alignment に残している [R25-R27]。これは「spatial は Attention/non-causal SSM、temporal は causal SSM」という分業を強く支持する。

ただし Mamba state だけに履歴を圧縮するのも危険である。RS-SSM は固定サイズ state が pixel-level specifics を忘れる問題を明示し、MS-Temba も naive Mamba が fine-grained temporal structure を潰すことを報告している [R35, R36]。したがって SAM2 では「recent raw memory + long-term Mamba state」の hybrid が理にかなう。

2026 年時点で「SAM2 + Mamba」だけでは新規性は不足する。SAM2 を使う SAM-Mamba (remote-sensing change detection)、SAMba-UNet、ReSurgSAM2、M2-SAM2、HilbertMed-SAM などがすでに存在する [R20-R24]。一方、SAM2 object-pointer sequence を persistent SSM state として扱う設計、あるいは SAMURAI の motion prior を Mamba の scan topology / gating / state transition に直接結びつける設計は、今回確認した主要文献群では明確な先行例が見つからず、差別化余地が大きい。

推奨順位は、(1) 小規模検証：Hybrid Spatial-Mamba Two-Way Decoder、(2) decoder 本命：Local-Global Target-Aware Mamba Decoder、(3) 研究本命：Temporal Object-Pointer Mamba、(4) 発展本命：Short-term Attention + Long-term Mamba Memory、(5) ハイリスク：Motion-Guided Dynamic Scan、(6) 補助案：Mask-Guided Memory-Encoder Mamba。全面 Mamba 化、単純 Hiera→VMamba 置換、generic Mamba decoder のみは避ける。

判断軸	結論	理由
Two-Way Transformer 全面置換	非推奨	prompt↔image content matching を cross-attention が担う。token 数も小さく、ここを消す計算上の必然性が弱い。
Cross-attention	原則保持	Mamba を dense spatial/temporal mixer に限定し、SAM 固有の promptability を維持。
Spatial Mamba	有望	64×64 級 dense token は長系列。VSSD/VMamba/LocalMamba 系の non-causal/local 設計と相性がよい。
Temporal Mamba	最有望	online propagation は因果的で、state carry が自然。pointer/history 圧縮へ直接的な必然性。
Mask/KF prior で scan 制御	高い新規性	SAMURAI 固有の prior を SSM 内部の情報伝搬ルールに使える。bbox 予測そのものとは異なる。
Generic SAM2+Mamba	弱い	2025–2026 年に複数の直接先行が存在。タスク固有 scan/state 設計が必要。


2. 調査範囲・Evidence Level

対象は 2023 年の Mamba 原論文から 2026 年 9 月 11 日まで。CVPR/ICCV/ECCV/NeurIPS/ICLR/AAAI/WACV/MICCAI、IEEE TIP/TPAMI/TMM/TCSVT/JBHI/JSTARS、主要 arXiv を中心に、原論文・公式 proceedings・出版社ページを優先した。GitHub や二次情報しか詳細を確認できない項目は強度を落として扱う。

Level	定義	本レポートでの扱い
A	査読済み原論文/公式 proceedings/出版社本文・公式コード	主要な結論・architecture 判断の根拠として使用。
A-	原著 arXiv/preprint 本文	最新設計の把握に使用。venue 未確定なら明記。
B	出版社 metadata/索引/二次的 abstract、原本文を十分確認できない	競合リスク確認には使うが、細部の architecture 断定は避ける。
C	GitHub のみ・第三者解説のみ	補助証拠。主要結論の単独根拠にはしない。

3. SAM2 / SAMURAI Architecture 整理

3.1 SAM2 の情報フロー



SAM2 は「simple transformer architecture with streaming memory」として設計され、動画を 1 フレームずつ処理しながら過去の object-aware memory を利用する [R37]。公式構成では mask memory 数は 7、memory attention は $d_{\text{model}}=256$ の 4 層、memory encoder は mask downsampling 後に pixel feature へ mask embedding を加算し、ConvNeXt 系 fuser で処理する [R39–R41]。SAM2.1 では object pointer に temporal positional encoding を付与する設定もある。

Module	現行構造	主な軸	役割	Mamba 観点
Image Encoder	Hiera hierarchical backbone + FPN neck	Spatial / multi-scale	高解像度 dense feature を作る。	Mamba backbone 置換は可能だが新規性弱。後回し。
Prompt Encoder	point/box = sparse token; mask = dense prompt	Target prior	「何を切るか」を定義。	原則保持。prior 生成源として使う。
Mask Decoder	Two-Way Transformer + upsampling + hypernetwork	Spatial + prompt conditioning	memory-conditioned image embedding と prompt を融合。	dense stream のみ SSM 化する価値大。
Token self-attention	sparse output/prompt token 間	Sparse semantic	mask token / prompt token の相互関係。	token 数小。Mamba 化の必然性低。
Token→Image cross-attn	sparse Q → dense K/V	Prompt→spatial matching	prompt がどの画像領域を見るか。	保持推奨。
Image→Token cross-attn	dense Q → sparse K/V	Prompt-conditioned image update	画像側へ prompt 情報を戻す。	保持推奨。後で削減 ablation 可能。
Object Pointer	mask decoder output token 由来の compact vector	Temporal / identity	高レベル target semantic を過去から保持。	Temporal Mamba の最重要候補。
Memory Encoder	pixel feature + predicted mask → memory feature	Spatial target memory	mask を直接 memory feature に注入。	Mask-guided Mamba 挿入の自然な場所。
Memory Bank	past mask memories + conditioning memories	Temporal storage	fixed-size / recent memory 中心。	raw+state hybrid へ拡張余地。
Memory Attention	current feature ↔ past memory cross-attn	Temporal retrieval	現在特徴を過去 memory で条件付け。	cross-attn 保持 + SSM long-term branch が有望。

3.2 SAMURAI が追加する motion / target prior

SAMURAI は SAM2 を再学習せず、Kalman filter による motion prediction と motion-aware memory selection を加える。初期フレームでは bbox、以後は previous predicted mask を prompt として使い、mask decoder が複数候補 mask と mask affinity / objectness を生成する。Kalman state は bbox 中心・サイズとその速度を含み、predicted bbox と各 candidate mask bbox の IoU (KF-IoU) を mask affinity と組み合わせて最終 mask を選ぶ。また mask affinity、object occurrence、motion consistency を用いて信頼できる memory だけを保持する [R42, R43]。

SAMURAI 信号	現在の使われ方	SSM へ拡張する案	研究上の意味
Previous mask	次フレームの dense prompt / target prior	local window、scan weight、input gate、memory update gate	「target-aware selective scan」を SAM2 固有に定義できる。
KF predicted bbox	candidate mask scoring	scan 開始点/方向、local ROI routing、state transition 条件、uncertainty-adaptive receptive field	motion を出力予測でなく情報伝搬規則へ使う。
KF velocity	state prediction	directional scan mixture の重み	移動方向に沿った先読み/情報収集という明確な仮説。
KF covariance/信頼度	現行では主に filter 内部	高不確実時は global branch、低不確実時は local branch	hard crop 失敗を避ける adaptive locality。
Mask affinity / objectness	mask selection / memory quality	SSM state update gate / reset gate	誤 memory を persistent state へ書き込むを防ぐ。

4. Vision Mamba 2024–2026 の研究潮流

4.1 Vanilla 1D causal scan からの脱却

Year	代表研究	主要改良	今回への示唆
2023	Mamba [R1]	Input-dependent selective SSM; causal recurrent scan	長系列・線形計算の原点。Vision 向け 2D inductive bias は未解決。
2024	Vim [R3]	Bidirectional	画像には前後文脈が必要という最初期の明示的適応。
2024	VMamba [R4]	SS2D / 4-route scan	2D adjacency と多方向 context を scan design で補う。
2024	LocalMamba [R5]	Windowed local scan + layer-wise scan choice	locality を保持しつつ global modeling 不足を抑制。
2024	QuadMamba [R7]	Learned quadtree partition/scan	固定 scan から content-adaptive topology へ。
2024	LoG-VMamba [R6]	Local-global arrangement + compressed global context	複雑 multi-scan に頼らず local/global 両立。
2025	Mamba-2 / SSD [R2]	SSD; Mamba-2 core 2–8× faster	SSM/attention の双対性から新しい core へ。
2025	VSSD [R8]	Non-causal SSD + multi-scan	画像で causality 自体を取り外す。
2025	MambaVision [R9]	Mamba + self-attention hybrid	後段 attention が long-range spatial を補完。
2025	DefMamba [R11]	Deformable/dynamic scan	重要領域を優先し、固定 flattening の欠点を回避。
2025	PVMamba [R12]	Dynamic spatial sampling + local restriction	sequential bottleneck と local modeling を同時に修正。
2025	DAMamba [R13]	Dynamic Adaptive Scan	scan 順序/領域を data-driven に学習。
2025	MambaOut [R10]	SSM 除去 control	「Mamba が必要か」を architecture-matched に検証。
2026	TMambaDet [R34]	Spatial Transformer + temporal bi-Mamba + hybrid decoder	次元ごとに Attention/Mamba を使い分ける設計が明示的。
2026	MS-Temba [R35]	Dilated multi-scale temporal SSM	naive Mamba の fine temporal collapse を修正。

4.2 「改良型が主流か」への回答

結論は「主要な新規 Vision Mamba 研究では、Yes」である。ただし“全 Vision Mamba 論文の何%”という統計ではない。2024 年には bidirectional / SS2D / local / learned scan が同時に出現し、2025 年には Mamba-2/SSD 由来の non-causal 化、Attention hybrid、deformable/dynamic scan が主要 venue で競争し、2026 年の video 系では spatial と temporal で異なる mixer を割り当てる設計が目立つ [R3–R13, R34–R36]。単に「Mamba block を置く」こと自体は新規性として弱く、どの軸をどう scan し、何を state に残し、何を Attention へ任せるかが主要設計変数になっている。

MambaOut からの警告

MambaOut は ImageNet 分類では SSM を外したモデルが Visual Mamba を上回り、Mamba は「長系列」かつ「autoregressive」な性質を持つタスクで特に自然だと主張する。一方、detection/segmentation では MambaOut が最良の Vision Mamba へ追いつかず、dense long-sequence task では SSM の余地がある [R10]。したがって本研究では「Mamba を足したら改善した」だけでは不十分で、matched Conv/MLP/MambaOut control が必須。

5. Segmentation × Mamba

Mask Decoder 設計に直接効くのは、backbone 全体を Mamba 化する研究より、decoder・multi-scale fusion・local/global detail refinement を Mamba で行う研究である。医用・remote sensing は SAM2 と domain が異なるが、高解像度 dense prediction で局所境界と長距離 context を両立する設計原理は転用できる。

Paper	Venue	Mamba 位置	Local/Global/Multi-scale	SAM2 decoder への関連	Ev.
-------	-------	----------	--------------------------	-------------------	-----

Paper	Venue	Mamba 位置	Local/Global/Multi-scale	SAM2 decoder への関連	Ev.
SegMamba	2024 MICCAI	3D encoder/U-shaped feature modeling	Tri-orientated Mamba; every scale; ~260k tokens	高次元 long sequence で Mamba の必然性が強いが、decoder 類似度は中。	A
LoG-VMamba	2024 ACCV	local-global segmentation backbone	spatially adjacent token を channel 軸で近接 + compressed global	SAM2 target 周辺 local + global context 設計に強く参考。	A
UNetMamba	2024 arXiv / IEEE GRSL 2025	Mamba Segmentation Decoder	MSD + train-only local supervision	decoder に Mamba を置く直接先行。generic decoder だけでは競合。	A-/A
PyramidMamba	2025 IJAE0	plug-and-play Mamba decoder	dense spatial pyramid pooling + Pyramid Fusion Mamba	multi-scale decoder/fusion の直接先行。	A
GLMambaNet	2025 IVC	Mamba decoder + local detail enhancement	global context Mamba + channel attention + gradient conv	「global Mamba + local boundary」 hybrid の直接先行。	A
Mamba as a Bridge	2025 CVPR	fusion / enhancer	Mamba fusion + hybrid Attention-Mamba	Foundation features の fusion 用途として局所 Mamba 導入の先行。	A

重要なのは、segmentation で Mamba が効く理由が「Transformer を置換できるから」ではなく、(i) dense token 列が長い、(ii) multi-scale 融合で冗長性を圧縮したい、(iii) global receptive field と local boundary の両立が必要、というタスク構造に結びつけられている点である [R6, R15–R19]。SAM2 Mask Decoder でも同じ論理を用いるべきである。

6. SAM / SAM2 × Mamba：直接競合

Paper	Year/Venue	Base	Task	位置	要点	競合評価	
Mamba (CV)	2025 WACV	SAM1	image / polyp	Encoder	Mamba-Prior を SAM image encoder へ注入	Mask Decoder/Memory とは違い。generic SAM+Mamba は既出。	A
baSAM	2025 JBHI	SAM1	medical image	Encoder adapter	軽量 VMamba branch + cross-branch attention	Mamba+Attention hybrid の直接前例。	A
oa-UNet	2025 arXiv	SAM2	cardiac MRI	Dual encoder/fusion	SAM2 + Mamba + UNet; heterogeneous fusion	SAM2 内部 memory ではない。	A
Mamba (RS)	2025 JSTARS	SAM2	bi-temporal change detection	Encoder + Mamba Decoder	SAM2 features → Mamba decoder + FGFR/DFM	「SAM2 + Mamba decoder」一般形は既出。競合リスク高。	A
rgSAM2	2025 MICCAI	SAM2	surgical RVOS	Detection stage + memory strategy	Cross-modal spatial-temporal Mamba; SAM2 tracking は credible/diverse memory	Mamba は SAM2 Two-Way/MemoryAttention 内部ではない。	A
rt-VLM / rtMed-SAM	2025 arXiv	SAM2 redesign	3D medical	scan + cross-attn + decoder	Hilbert space-filling Mamba + HMCA + scale-aware decoder	custom scan + cross-attn は新規性競合。domain は違い。	A
AM2	2026 TCSVT	SAM2	RVOS	Temporal prompt + spatial scanner	Mamba-MoE state propagation; language-guided multi-directional spatial scan	target/prompt temporal state に近い。全文未検証なので細部は B。	B

* JSTARS 論文は査読済み publication metadata を確認し、architecture の詳細は公開 author version から確認したため、細部は A/B の混合扱い。M2-SAM2 は DOI/metadata と二次 abstract を確認したが原全文を十分確認できていないため B。

新規性の最低条件

2026 年に「SAM2 の decoder へ Mamba を入れた」だけでは弱い。少なくとも (1) SAM2 固有の prompt/image 双方向 interaction を保持・再設計、(2) previous mask / object pointer / motion prior を SSM の selection/state へ結びつける、(3) spatial causality を明示的に non-causal 化、(4) MambaOut-style control で SSM の必然性を示す、のいずれか複数が必要。

7. Tracking / Video / Memory × Mamba

7.1 Tracking では「時間 state」に Mamba を使う必然性が強い

paper	Venue	SSM 設計	軸	核心	SAM2/SAMURAI 示唆
CT	2025 AAAI	Unidirectional Context Mamba	Temporal	first→current frame を連続 scan し target variation cue を hidden state へ集約。cue を Attention へ注入。	SAM2 pointer/history に最も直接的な設計原理。
LT	2025 CVPR	time-evolving hybrid SSM + selective locality	Temporal + local spatial	continuous temporal state; adaptive reference update; modality-guided bidirectional scan	target-aware state + locality の強い前例。
	2026 TIP	state-aware Mamba	Temporal	state-wise parameters; hidden state propagation/update で全過去と線形 interaction	object pointer persistent state の最重要前例。
	2026 TMM	Target-Aware Mamba	Temporal target state	search state + static template + compressed history を selective bidirectional interaction	target-aware gating への近接競合。詳細は B。
MOT	2025 ICASSP	Mamba motion predictor	Trajectory	bbox/motion prediction	今回の主軸とは異なる。避けるべき差別化対象。
	online 2025 / TPAMI 2026	Motion-Aware Mamba / MDSS	Temporal motion	egomotion を motion-driven selective scan へ統合	KF motion を scan/state control に入れる根拠。

7.2 Video / Memory 研究からの設計原理

研究	Venue	設計	今回への示唆
TMambaDet	2026 CVPR	Spatial deformable Transformer / Temporal cascaded bidirectional Mamba / Mamba-entangled decoder	spatial と temporal で mixer を分業。query-feature alignment は hybrid。
HieraMamba	2026 CVPR	Anchor-MambaPooling による hierarchical temporal compression	long memory を 1 個の state だけでなく multi-scale anchor へ圧縮する発想。
MS-Temba	2026 CVPR	dilated SSM + multi-scale temporal fuser	naive Mamba は fine temporal structure を潰す。複数時間尺度が必要。
RS-SSM	2026 CVPR	fixed state で失われる specifics を refine	pixel-level VOS では state-only 圧縮が危険。recent raw memory 併用が合理的。
SAM4D	2025 ICCV	Motion-aware memory attention with ego-motion alignment	motion を memory retrieval 前の alignment/conditioning へ使う直接的 SAM2 派生前例。
SAM2Long	2025 ICCV	uncertainty-aware memory tree	SAM2 の greedy memory による error accumulation を実証。長期 memory 改善余地。
Efficient-SAM2	2026 ICLR	previous decoder saliency で Sparse Window Routing + Sparse Memory Retrieval	previous-frame target saliency で空間 routing/memory token 選択する発想を直接支持。
SAMURAI++	2026 CVPR Findings	short-term motion-aware + long-term instance memory	two-timescale memory を SAM2 MOT で有効化。raw+state hybrid の構造的根拠。

8. 研究上の 10 問への回答

問い	回答
1. 改良型が主流か？	主要 venue の新規設計という意味では Yes。bidirectional/SS2D/local/non-causal/dynamic/hybrid が中心。ただし全論文を数えた bibliometric majority ではない。
2. Two-Way Transformer 完全置換は妥当か？	原則 No。Two-Way Transformer は prompt/output token と image feature の双方向 alignment 装置。全面置換は SAM 固有能力を捨てる割に、sparse token 側の計算削減メリットが小さい。
3. prompt-image cross-attention は残すべきか？	Yes。少なくとも初期設計では token→image と image→token の両方を保持。Mamba は dense image stream の spatial/temporal mixing へ使う。
4. dense image token 側 spatial mixer は妥当か？	Yes。Mask Decoder の dense stream には image-to-image self-attention がないため、non-causal 2D SSM を residual で追加する仮説が明確。64×64 級の長い dense sequence にも適合。

問い	回答
5. LocalMamba / Local-Global は相性良いか？	良い。target mask 周辺の boundary/detail を local branch、distractor や re-entry を global branch で見る。ただし hard crop ではなく uncertainty-aware soft routing が望ましい。
6. previous mask/KF bbox を scan/gating/init/routing に使うのは自然か？	非常に自然。Efficient-SAM2 は previous decoder saliency で routing、MADiff は motion-driven selective scan、DefMamba/DAMamba は dynamic scan を実証。SAMURAI prior を SSM 内部制御へ使えば独自性が出る。
7. Decoder より Memory/pointer の方が Mamba 向きか？	「Mamba の必然性」では Memory/pointer が上。online temporal propagation は causal state carry そのもの。ただし SAM2 既定 memory 長が短いままでは利点が小さいため、persistent state や長期 history 拡張とセットにする。
8. spatial non-causal / temporal causal の使い分けは？	強く推奨。画像空間は順序に因果性がないため NC-SSD/2D bidirectional、online tracking 時間は過去→現在のみの causal Mamba。offline VOS なら時間方向 bidirectional も追加 ablation。
9. 「SAM2 + Mamba」だけで新規性は？	不足。SAM2 encoder+Mamba decoder、SAM2+Mamba dual encoder、RVOS の Mamba-MoE、Hilbert scan などがすでに存在。固有 prior/state 設計が必要。
10. どう差別化するか？	SAM2/SAMURAI にしかない previous mask、object pointer、mask quality/objectness、Kalman motion、memory selection を Mamba の scan/state transition/update gate へ直接組み込み、Attention との分業と MambaOut control を明示する。

9. SAM2 / SAMURAI 向け Architecture 候補

以下は「Mamba で置換する場所」ではなく、「Mamba の selective state / linear long-sequence modeling が必要になる理由」から逆算した 6 案である。A→B は decoder 系の漸進的研究、E→F は temporal memory 系の本命、C は高新規性・高リスク、D は SAM2-native な中リスク案。

A. Hybrid Spatial-Mamba Two-Way Decoder

項目	評価
変更 module	Mask Decoder / 各 Two-Way block の dense image stream
概要	sparse self-attn → token→image cross-attn → **NC-SSD/2D Mamba on dense K** → token MLP → image→token cross-attn。Mamba branch は residual + LayerScale で追加。
借りる idea	VSSD/VMamba/MambaVision。
Mamba 必然性	Dense H×W が長系列で、Two-Way block に不足する image-to-image spatial mixing を線形 complexity で追加。
残す Attention	両 cross-attn + sparse self-attn
Mamba 部分	dense image features のみ
Tensor イメージ	K: B×HW×256 → reshape B×H×W×256 → Mamba2D → B×HW×256
軸	Spatial, non-causal
難度	中
Cost	中
期待改善	境界/遮蔽時の context 改善を期待
欠点	generic Mamba decoder との差別化が弱い
Training	比較的容易。pretrained path を壊さない zero/small init 推奨
新規性	中
競合	中～高
論文化	★★★★☆

B. Local-Global Target-Aware Mamba Decoder

項目	評価
変更 module	Mask Decoder dense stream + target prior router
概要	previous mask + KF bbox/uncertainty から soft target map P を作り、target 周辺の high-res local Mamba と、downsampled global NC-SSD を並列。uncertainty/quality で融合 gate を変える。
借りる idea	LocalMamba, LoG-VMamba, MSVMamba, Efficient-SAM2。
Mamba 必然性	segmentation は local boundary と global distractor context の両方が必要。prior で計算・状態を target-aware にできる。
残す Attention	prompt↔image cross-attn
Mamba 部分	local/global dense spatial mixer
Tensor イメージ	F_hi: $B \times H \times W \times C$; ROI windows $\rightarrow$ local SSM。F_low: $B \times H/s \times W/s \times C \rightarrow$ global NC-SSD。fuse $g(P, \Sigma)$ 。
軸	Spatial, non-causal
難度	中～高
Cost	中
期待改善	target detail、distractor 抑制、efficiency
欠点	prior 誤りで target を見失う。hard crop は危険
Training	soft routing、oracle prior から curriculum すると安定
新規性	高
競合	中
論文化	★★★★☆

C. Motion-Guided Dynamic Scan Mamba Decoder

項目	評価
変更 module	Mask Decoder or Memory Encoder spatial SSM
概要	KF velocity/box/uncertainty で 4/8 方向 scan mixture 重みを決める。発展形では offset/deformable scan、 $\Delta/B/C$ や state gate も motion-conditioned。
借りる idea	DefMamba, DAMamba, MADiff(MDSS), SAMURAI。
Mamba 必然性	motion prior が「次にどこを見るか」を直接規定し、selective scan の構造へ意味を与える。
残す Attention	cross-attn は保持
Mamba 部分	scan topology / SSM parameter gating
Tensor イメージ	$v_t, \Sigma_t, P_{t-1} \rightarrow$ router $\rightarrow \{w_{dir}\}$; $F \rightarrow \Sigma_d w_d$ SSM_d(F)。
軸	Spatial+motion conditioned
難度	高
Cost	中～高
期待改善	fast motion/occlusion で大きな改善余地
欠点	kernel 実装・学習不安定、scan 順序の離散性
Training	まず fixed directions の soft mixture。deformable は後段
新規性	非常に高
競合	中

項目	評価
論文化	★★★★☆ (成功時★★★★★)

D. Mask-Guided Memory-Encoder Mamba

項目	評価
変更 module	Memory Encoder fuser
概要	MemoryEncoder の $x = \text{pix_proj}(\text{feature}) + \text{mask_embedding}$ の直後で、ConvNeXt fuser を mask-gated local/global NC-SSD へ置換/追加。
借りる idea	LoG-VMamba, VSSD, Efficient-SAM2。
Mamba 必然性	SAM2 は mask を memory feature へ直接注入するので、mask-conditioned selective state が自然。
残す Attention	Memory Attention は完全保持
Mamba 部分	memory feature spatial encoding
Tensor イメージ	$x: B \times 256 \times 64 \times 64 \rightarrow \text{mask-gated 2D SSM} \rightarrow \text{out_proj } B \times 64 \times 64 \times 64$ 。
軸	Spatial memory encoding
難度	中
Cost	中
期待改善	memory quality、boundary/foreground purity
欠点	memory encoder は既に軽い ConvNeXt で、gain が小さい可能性
Training	新 branch residual で段階導入
新規性	中～高
競合	中
論文化	★★★★☆～★★★★★

E. Temporal Object-Pointer Mamba

項目	評価
変更 module	Object pointer history / Memory Attention input
概要	各 frame の object pointer に mask quality/objectness/KF motion/pooled target appearance を付加して causal Mamba state h_t へ更新。recent raw pointers と state token を Memory Attention へ渡す。
借りる idea	MambaLCT, MambaVLT, SMTrack, SAM2 object pointer。
Mamba 必然性	online tracking の長期 target identity/appearance 変化は causal state carry と一致。raw history を全保存せず長期化できる。
残す Attention	current→memory cross-attn は保持
Mamba 部分	temporal pointer/state aggregation
Tensor イメージ	$z_t: B \times D \rightarrow \text{causal Mamba} \rightarrow h_t$ 。proj(h_t)→ $r \times 256$ state pointer tokens; memory KV へ append。
軸	Temporal, causal
難度	中～高
Cost	低～中 (state は O(1) carry)
期待改善	long-term identity、re-entry、appearance drift
欠点	state contamination / wrong-mask accumulation

項目	評価
Training	quality-gated update、no-object reset、TBPTT/long clips が必要
新規性	非常に高
競合	低～中
論文化	★★★★★

F. Short-term Attention + Long-term Mamba Memory

項目	評価
変更 module	Memory Bank + Memory Attention
概要	recent raw mask memories は現行 cross-attention で高精細に参照。古い履歴は causal Mamba/anchor state へ圧縮し、[recent raw KV; long-term state tokens; pointer state] へ current feature が cross-attend。
借りる idea	SAMURAI++, HieraMamba, MambaLCT, RS-SSM。
Mamba 必然性	Mamba の long-term state と Attention の content-addressed pixel detail を補完的に使える。state-only 忘却も避ける。
残す Attention	Memory cross-attn
Mamba 部分	old-history compression / temporal state
Tensor イメージ	M_recent: K×(HW)×64 + S_long: r×64/256 + pointers → MemoryAttention。
軸	Temporal + memory retrieval
難度	高
Cost	中～高
期待改善	長期 VOS/MOT の occlusion/reappearance に最大期待
欠点	メモリ設計が複雑、train/inference state 管理が難しい
Training	short→long curriculum、quality gate、state detach/TBPTT 設計
新規性	非常に高
競合	中
論文化	★★★★★

10. Architecture 比較・最終優先順位

案	Mamba 必然性/5	新規性/5	期待 gain/5	risk/5	位置付け	判断
Temporal Object-Pointer Mamba	5.0	4.6	4.2	3.3	本命（単一 module）	Mamba の state carry 必然性が最も強く、SAM2 obj pointer という固有構造を使える。
Local-Global Target-Aware decoder	4.2	4.3	4.2	3.2	decoder 本命	decoder 研究として最もバランスがよい。previous mask/KF prior で generic Mamba decoder から差別化。
Short-term Attn + Long-term Mamba Memory	5.0	4.7	4.6	4.1	発展本命 / flagship	長期 memory 問題へ正面から答える。SAMURAI++/SAM2Long の問題設定とも合う。
Motion-Guided Dynamic Scan	4.5	4.8	4.3	4.6	High-risk / high-return	scan topology へ motion を入れる新規性が大きいが装・学習リスクも最大。
Mask-Guided Memory Encoder	3.7	3.7	3.4	2.6	補助/独立実験	SAM2-native だが MemoryAttention ほど Mamba の必然性は強くない。
Hybrid Spatial-Mamba Two-Way	3.2	2.8	3.2	2.4	最初の小規模実験	安全な sanity check。単独では新規性が足りないため B/C への足場。

10.1 まず試すべきもの

- **A Hybrid Spatial-Mamba Two-Way Decoder** : 「cross-attn は残して dense mixer のみ変える」という研究仮説を最小変更で検証する。ここで vanilla Mamba が効かず NC-SSD/SS2D だけが効くなら、潮流と整合する強い結果になる。
- **D Mask-Guided Memory Encoder** : MemoryEncoder fuser の差し替え/追加は独立性が高く、Mask-guided SSM の有効性を早く判定できる。ただし本命化は gain 次第。

10.2 本命 Architecture

- **E Temporal Object-Pointer Mamba** : 最も Mamba らしい。SAM2.1 が既に past object pointer → temporal positional encoding を与えているため、「離散 pointer 列を continuous selective state へする」という論理が自然。long-term history を増やすことで MambaOut の“long/autoregressive”条件も満たせる。
- **B Local-Global Target-Aware Mamba Decoder** : Mask Decoder を主戦場にする場合の本命。単なる 2D Mamba ではなく、previous mask/KF uncertainty が local/global route を決めるところまで入れて論文化する。

10.3 High-risk / High-return

- **C Motion-Guided Dynamic Scan** : KF velocity/covariance を scan 方向や state transition へ直接入れる。うまくいけば最も独自だが、まず soft mixture of fixed scans で仮説検証し、deformable scan は後段。
- **F Hybrid Long-term Memory** : raw recent memory と long-term state を統合する完成形。長期 VOS/MOT へ強いが、学習・state 管理・評価が重い。E が効いてから拡張。

10.4 避けるべきもの

- **Two-Way Transformer 全面 Mamba 化** : prompt-conditioned decoding を壊す可能性が高く、なぜ Mamba かの説明も弱い。negative/control ablation としてのみ価値。
- **Hiera/Image Encoder を VMamba へ丸ごと交換** : 既存 Vision Mamba/SAM-Mamba 系と競合しやすく、SAM2 固有の研究になりにくい。
- **Generic Mamba Decoder** : JSTARS SAM-Mamba、UNetMamba、PyramidMamba などと近すぎる。target/motion/memory-aware 機構なしでは弱い。
- **Mamba trajectory predictor のみ** : MambaMOT 等と直接競合し、現在の研究主軸「SAM2/SAMURAI 内部 architecture」とずれる。

11. Ablation / 実験計画

11.1 SSM そのものの効果を分離する必須 Control

```
Baseline SAM2 / SAM2.1 / SAMURAI
↓
Matched-parameter Conv / DWConv / ConvNeXt or MLP
↓
MambaOut-style gated conv (same shell, SSM removed)
↓
vanilla causal/raster Mamba
↓
bidirectional Mamba / VMamba SS2D
↓
Mamba-2 / SSD → non-causal VSSD-style mixer
↓
Local only / Global only / Local-Global
↓
Mask-guided / Motion-guided / Target-aware routing
```

この順序により、(a) parameter を増やした効果、(b) local convolution inductive bias、(c) SSM そのもの、(d) vision 向け non-causal/2D 化、(e) task-specific prior の価値を分離できる。特に MambaOut-style control は必須で、Mamba block から SSM token mixer だけを除いた同等 architecture を用意する [R10]。

Ablation 軸	比較	答える問い
Mixer control	Baseline / MLP / DWConv / ConvNeXt / MambaOut-block / vanilla Mamba / Bi-Mamba / SS2D / NC-SSD	SSM だから効いたか。
Causality	causal raster / reverse / bidirectional / 4-way / non-causal SSD	画像で causality を捨てる価値。
Locality	global-only / local-only / local-global / matched receptive-field Conv	local Mamba 特有の効果。
Cross-attention	両方向維持 / token→image のみ / image→token のみ / cross-attn なし完全 Mamba	SAM prompt alignment の必要性。
Mamba 位置	cross-attn 前 / between cross-attns / cross-attn 後 / parallel residual	interaction 順序の意味。
Target prior	none / shuffled prior / GT oracle / previous mask / KF bbox / mask+KF / uncertainty-weighted	prior 情報自体と正しい routing の寄与を分離。
Motion signal	center only / +velocity / +scale velocity / +covariance	motion-guided scan の最小十分情報。
Guide mechanism	concat only / feature gate / scan-direction weight / Δ,B,C conditioning / state init / routing	「prior を入れただけ」と selective state control を分離。
Temporal state	last pointer / EMA / GRU/LSTM / temporal Transformer / Mamba / Mamba-2 / state-aware Mamba	Mamba の時間 state 優位性。
History length	7 / 16 / 32 / 64 / all-history state carry	SAM2 既定短 memory でなく long context で差が出るか。
Memory form	SAM2 FIFO / SAMURAI selection / state-only / recent raw + long state / pointer-state only	raw detail と compressed state の役割。
Update quality	always update / mask-quality gate / objectness gate / motion gate / combined / reset on no-object	state contamination 対策。

11.2 評価データと failure-stratified analysis

用途	候補 dataset/metric	特に見る属性
VOS	SA-V, MOSE, LVOS, DAVIS, YouTube-VOS; J&F/J/F	長期遮蔽、reappearance、fast motion、small object、distractor、mask boundary。
SOT/VOT	LaSOT/LaSOText, GOT-10k, TrackingNet, VOT; AUC/AO/EAO	fast motion、occlusion、deformation、out-of-view、similar object。
MOT	DanceTrack, MOT17; HOTA/AssA/DetA/IDF1	交差、crowd、identity switch、detector miss。
Efficiency	FPS/wall-clock, peak VRAM, params, FLOPs/MACs, state memory	scan kernel overhead を FLOPs だけで判断しない。

11.3 Training strategy

- 最初は Hiera/Image Encoder を freeze し、新規 SSM と decoder/memory 周辺だけを学習。full fine-tune との差は後で確認する。
- pretrained path を壊さないよう、Mamba residual branch は LayerScale または scalar α を 0～小値で初期化する。
- Temporal state は mask quality / objectness / KF consistency で update gate を設け、誤 mask が長期 state へ永久注入されるのを防ぐ。
- 長期 state 学習は短 clip→長 clip の curriculum、TBPTT/state detach interval を明示的に ablate する。
- 少なくとも 3 seeds。overall score だけでなく、fast-motion/occlusion/long-term subset で有意な改善が再現するかを見る。

12. 主要論文比較表

表は読みやすさのため、ユーザー指定項目を「基本属性」「scan/interaction」「計算・ablation・競合」の3表へ分割した。NR = 本調査で原論文から信頼して抽出できなかった/variant 依存のため未記載。

Paper	Year	Venue	Task	SSM type	位置	Modeling 軸	Tokenization
Mamba	2023	arXiv	sequence modeling	Mamba SSM	Backbone/core	Temporal/sequence	1D tokens
Mamba-2 / SSD	2024	ICML	sequence modeling	SSD / Mamba-2	Core	Temporal/sequence	1D tokens
Vim	2024	ICML	vision backbone	Bidirectional Mamba	Encoder	Spatial	patch sequence + pos emb
VMamba	2024	NeurIPS	vision backbone/dense	VSS/SS2D	Encoder	Spatial	2D patches → 4 routes
LocalMamba	2024	ECCV Workshops	vision backbone	Mamba local scan	Encoder	Spatial	local windows
MSVMamba	2024	NeurIPS	vision backbone/dense	multi-scale VSS	Encoder	Spatial/multi-scale	original + downsampled maps
QuadMamba	2024	NeurIPS	vision backbone	quadtree Mamba	Encoder	Spatial	adaptive quadrants
LoG-VMamba	2024	ACCV	medical segmentation	local-global VMamba	Encoder/decoder net	Spatial	local arrangement + compressed global
VSSD	2025	ICCV	vision backbone/dense	NC-SSD (Mamba-2 family)	Encoder	Spatial	hierarchical image tokens
MambaVision	2025	CVPR	vision backbone	hybrid Mamba/Attention	Encoder	Spatial	hierarchical windows/features
MambaOut	2025	CVPR	vision backbone/control	SSM-removed gated block	Encoder	Spatial	image tokens
DefMamba	2025	CVPR	vision backbone/dense	deformable Mamba	Encoder	Spatial	dynamic scan path
PVMamba	2025	ICCV	vision backbone/dense	Dynamic State Aggregation	Encoder	Spatial	dynamic local sampling
DAMamba	2025	NeurIPS	vision backbone/dense	Dynamic Adaptive Scan	Encoder	Spatial	learned scan order/region
SegMamba	2024	MICCAI	3D medical seg	tri-orientated Mamba	Multi-scale encoder	Spatial 3D	volume tokens (~260k)
UNetMamba	2024/25	arXiv / GRSL	remote sensing seg	Mamba decoder	Decoder	Spatial	multi-scale encoder features
PyramidMamba	2025	IJAE0	remote sensing seg	Pyramid Fusion Mamba	Decoder	Spatial/multi-scale	pyramid pooled features
GLMambaNet	2025	IVC	remote sensing seg	Mamba global-context decoder	Decoder	Spatial	multi-scale Swin features
SAM-Mamba	2025	WACV	polyp segmentation	Mamba prior	SAM1 Encoder	Spatial	multi-scale prior
MambaSAM	2025	JBHI	medical segmentation	VMamba adapter	SAM1 Encoder adapter	Spatial	parallel SAM/VMamba branches
SAM-Mamba CD	2025	JSTARS	change detection	VSS/Mamba decoder	SAM2 Encoder + Decoder	Spatial/bitemporal	dual-temporal features
ReSurgSAM2	2025	MICCAI	surgical RVOS	spatial-temporal Mamba	Pre-SAM2 detection	Spatial/temporal	vision+text features
M2-SAM2	2026	TCSVT	RVOS	Mamba-MoE	Prompt + spatial scanner	Temporal/spatial	prompt states + image tokens
MambaLCT	2025	AAAI	SOT	unidirectional Context Mamba	Temporal context module	Temporal	frame features

Paper	Year	Venue	Task	SSM type	位置	Modeling 軸	Tokenization
MambaVLT	2025	CVPR	V-L tracking	time-evolving hybrid SSM	Tracker core	Temporal/spatial	multimodal target/reference
SMTrack	2026	TIP	SOT	state-aware Mamba	Temporal module	Temporal	tracked frame features/state
MADiff	2025/26	TPAMI	trajectory prediction	motion-aware Mamba / MDSS	Denoiser	Temporal/motion	video/motion tokens
TMambaDet	2026	CVPR	video object detection	bi-Mamba + Transformer hybrid	Temporal encoder + decoder	Spatial/temporal	frame/object tokens
MS-Temba	2026	CVPR	long video TAD	dilated temporal Mamba	Temporal encoder/fuser	Temporal/multi-scale	video temporal features
RS-SSM	2026	CVPR	video semantic seg	refined SSM	Temporal/spatial	Spatiotemporal	pixel-level video features

Paper	Scan	Causal?	Local	Global	Attention 併用	Cross-Attn	Multi-scale	Target-aware
Mamba	causal 1D selective scan	causal	local conv inside block	global via recurrent state	No	No	No	input-dependent selection
Mamba-2	SSD	causal	No explicit	global sequence	No	No	No	selective/SSD
Vim	forward+backward	bidirectional	implicit patch locality	whole image	No	No	No	No
VMamba	4-way SS2D	effectively multi-directional	2D inductive bias	whole feature map	No	No	hierarchical	No
LocalMamba	windowed scan + chosen directions	multi-dir within windows	Yes, window	layer/global via design	No	No	hierarchical	No
MSVMamba	multi-scale 2D scans	multi-directional	original-scale local	downsampled global	ConvFFN	No	Yes	No
QuadMamba	learned quadtree + shifted windows	adaptive multi-dir	adaptive locality	cross-region via shifts	No	No	Yes	content-adaptive
LoG-VMamba	simple scan on local/global arrangement	non-autoregressive vision use	explicit local	compressed global context	No/architecture-dependent	No	Yes	No
VSSD	NC-SSD + multi-scan	non-causal	LPU/local bias	global NC-SSD	hybrid final attention in variants	No	hierarchical	foreground-selective weight m
MambaVision	redesigned Mamba + window hierarchy	non-causal vision block behavior	conv/local windows	later self-attention	Yes	No	Yes	No
MambaOut	no SSM	N/A	gated conv	no SSM global state	No	No	hierarchical	N/A
DefMamba	deformable scanning	non-causal vision application	dynamic structure	multi-scale global	No	No	Yes	dynamic important regions
PVMamba	dynamic spatial sampling/aggregation	non-causal vision application	neighbor restriction shallow	aggregation deeper	No	No	Yes	Yes
DAMamba	data-driven order + region	non-causal vision application	adaptive	global maintained	No	No	Yes	Yes
SegMamba	tri-oriented 3D	multi-directional	3D local modules	whole-volume state	CNN hybrid	No	Yes	No
UNetMamba	decoder selective scan	vision/non-causal style	local supervision	decoder long-range	CNN/UNet hybrid	No	Yes	No
PyramidMamba	pyramid fusion scan	vision/non-causal style	DSPP	pyramid global fusion	CNN/Mamba	No	Yes	No

Paper	Scan	Causal?	Local	Global	Attention 併用	Cross-Attn	Multi-scale	Target-aware
GLMambaNet	global-context Mamba	vision/non-causal style	gradient conv detail	Mamba global	channel attention	No	Yes	No
SAM-Mamba WACV	Mamba prior multi-scale	vision	local clues	global dependencies	SAM encoder fusion	SAM decoder remains	Yes	polyp prior
MambaSAM	VMamba branch	vision	local/global branch	global VMamba	Cross-branch attention	Yes between branches	Yes	domain-adaptive
SAM-Mamba CD	VSS decoder	vision	FGFR detail	Mamba/DFM context	hybrid modules	prompt cross-attn not core	Yes	coarse mask/box prompt
ReSurgSAM2	spatial-temporal Mamba	temporal state + spatial	Yes	long temporal	cross-modal fusion	SAM2 tracking retains	Yes	text target
M2-SAM2	multi-dir spatial + temporal state	temporal causal-like; spatial multi-dir	conditional spatial refinement	Mamba state propagation	MoE/adapters	cross-modal language conditioning	Yes	language/foreground prompt
MambaLCT	frames scanned first→current	causal/unidirectional	N/A	all-history state	Attention retained downstream	Yes (cue injected to attention)	Temporal	target variation
MambaVLT	time-evolving + modality-guided bidirectional	hybrid	selective locality enhancement	continuous temporal state	hybrid	multimodal interaction	Temporal	target/reference aware
SMTrack	state-wise selective SSM	causal temporal	N/A	persistent hidden state	tracker attention can remain	task-dependent	Temporal	state-aware
MADiff	motion-driven selective scan	causal motion modeling	N/A	temporal motion state	diffusion framework	No	Temporal	egomotion-guided
TMambaDet	temporal cascaded bi-Mamba	bidirectional temporal	deformable spatial attention	long frame sequence	Yes	query-feature alignment in hybrid decoder	Yes	object query-aware
MS-Temba	dilated SSMs	temporal	multi-scale temporal locality	long temporal	No	No	Yes	action-aware via loss
RS-SSM	SSM + forgotten-specific refiner	temporal state	pixel-specific refinement	state compression	hybrid refiner	No	Video	pixel-specific

Paper	Complexity	Params	FLOPs	代表 Ablation/Result	SAM2/SAMURAI 応用	競合 risk
Mamba	linear sequence; 5× LM inference throughput claim	variant	variant	selectivity + hardware-aware scan	基礎	低（直接競合でない）
Mamba-2	core 2–8× faster than Mamba	variant	variant	SSD/Mamba-2 speedup	Mamba-2 採用候補	低
Vim	linear SSM; 1 248 ² feature inference 2.8× DeiT, -86.8% GPU mem	variant	variant	Bi-Mamba > visual baselines in paper	bidirectional baseline	低
VMamba	linear in tokens	variant	variant	SS2D essential design	2D baseline	低
LocalMamba	same-scale efficient window scan	variant	~1.5G (Ti-scale)	Vim-Ti 比 +3.1pt reported	local branch idea	低
MSVMamba	efficient multi-scale scan	variant	variant	Tiny 83.0 IN1K; 47.9 ADE20K	global coarse branch	低
QuadMamba	linear SSM + learned partition overhead	NR	NR	adaptive quadtree improves multiple tasks	dynamic target routing precedent	中
LoG-VMamba	linear/simple scan	variant	variant	local+global design superior to baselines	B 案の強い先行原理	中
VSSD	linear NC-SSD	~24M (Tiny)	~4.5G	SSD 82.0 → Bi 82.4 → NC 82.8 in representative ablation; later variant numbers differ	spatial NC-SSD 第一候補	低
MambaVision	hybrid	31.8M (T, code)	4.4G (T, code)	late self-attn improves long-range	Attention を残す根拠	低

Paper	Complexity	Params	FLOPs	代表 Ablation/Result	SAM2/SAMURAI 応用	競合 risk
MambaOut	Conv-like	27M (T)	4.5G (T)	ImageNet で Visual Mamba 超; dense tasks では最良 Mamba に未達	必須 negative/control	低
DefMamba	linear-ish + deformable routing overhead	variant	variant	dynamic path improves dense tasks	C 案 precedent	中
PVMamba	linear complexity claimed	variant	variant	dynamic state aggregation/local restriction	C/B 案 precedent	中
DAMamba	linear complexity maintained	variant	variant	dynamic adaptive scan > fixed visual Mamba	C 案 precedent	中
SegMamba	long-volume efficient	NR	NR	~260k token whole-volume modeling	long dense seq の必然性	低
UNetMamba	lightweight decoder	NR	NR	LoveDA +0.87 mIoU, Vaihingen +0.39	generic decoder 競合	中～高
PyramidMamba	real-time oriented	NR	NR	OpenEarthMap 70.8 mIoU 等	multiscale decoder 競合	中
GLMambaNet	linear decoder	NR	NR	boundary/global module ablations reported	local-global decoder 競合	中
SAM-Mamba WACV	adapter overhead	NR	NR	Mamba-Prior improves five polyp datasets	SAM1 encoder only	低～中
MambaSAM	minimal trainable params	NR	NR	ACDC limited-data Dice +0.18 vs AutoSAM reported	hybrid SAM/Mamba precedent	低～中
SAM-Mamba CD	NR	NR	NR	LEVIR/WHU/SYSU improvements; module ablations	generic SAM2 Mamba decoder already exists	高
ReSurgSAM2	61.2 FPS reported	NR	NR	CSTMamba + credible init + DLM effective	SAM2 video + Mamba precedent	中～高
M2-SAM2	NR	NR	NR	reported SOTA; details not fully verified	temporal prompt + multi-dir target scan near-competitor	高
MambaLCT	linear temporal state; real-time	variant	variant	long-term context improves 6 benchmarks	E/F に最重要	中
MambaVLT	linear temporal state	variant	variant	continuous state/ref update gains	E/B precedent	中
SMTTrack	linear temporal training/state carry	NR	NR	state-wise parameters + propagation effective	E に最重要	中～高
MADiff	SSM denoiser	NR	NR	motion-driven scan improves trajectory prediction	C の motion→scan 根拠	中
TMambaDet	spatial attention quadratic/local deformable + temporal Mamba linear	NR	NR	hybrid components collectively SOTA	spatial/temporal 分業の強根拠	低
MS-Temba	efficient; 17M	17M	NR	naive Mamba fine temporal collapse; dilated/multi-scale fixes	F の multi-timescale 設計	低
RS-SSM	efficient state compression + refinement	NR	NR	forgotten-specific refinement improves VSS	state-only memory への警告	低

13. 新規性分析：どこまでやれば論文になるか

競合リスクを最小化するには、architecture name に“Mamba”が入ることではなく、SAM2/SAMURAI の固有 signal が SSM の数理的・構造的役割を変えることが重要である。以下の順に新規性が強くなる。

1. 弱：Two-Way Transformer の一部を vanilla Mamba block へ置換。
2. やや弱：dense image token へ SS2D/NC-SSD を追加。性能改善があっても generic decoder adaptation と見られやすい。
3. 中：Local-Global Mamba を decoder に導入し、cross-attention を残す。local/global design 自体の先行が多いため、SAM2 固有 prior が必要。
4. 強：previous mask / KF uncertainty で local-global route や scan direction を動的に決める。SSM の information flow が tracking state に依存する。
5. 強：object pointer を causal Mamba state に変換し、quality-aware update/reset で persistent target state を構成。SAM2 固有の semantic memory と Mamba の state carry を直結。
6. 最強候補：recent raw spatial memory + long-term Mamba pointer/state を二時間尺度で融合し、occlusion/re-entry/error accumulation 問題を明示的に解く。

論文の主張として狙いやすい形

“We do not replace SAM2 attention with Mamba. We factorize SAM2 tracking into non-causal target-conditioned spatial mixing and causal persistent target-state modeling, where SAMURAI motion/mask priors control selective state propagation.” という主張なら、既存の generic SAM2+Mamba や bbox trajectory Mamba と明確に違う。

14. 推奨する研究方針・実験ロードマップ

段階	実験	Go/No-Go 基準
Phase 0: Baseline 固定	SAM2.1 / SAMURAI baseline を再現し、dataset・metric・seed・efficiency 計測を固定。	以後の変更を 1 module ずつ比較できる状態にする。
Phase 1: Decoder mixer sanity	A 案。Conv/MLP/MambaOut/vanilla/Bi/SS2D/NC-SSD を同一位置・同程度 params で比較。	「Mamba だから効くか」「non-causal 化が必要か」を最短で確認。
Phase 2: Target-aware spatial	B 案。previous mask → soft local/global routing。次に KF uncertainty を追加。	Mask Decoder 本命。ここで明確な gain が出れば独立論文軸。
Phase 3: Persistent pointer state	E 案。object pointer + quality + motion → causal Mamba state。history 7→64+へ。	Mamba の技術的必然性を最も強く示す本命。
Phase 4: Two-timescale memory	F 案。recent raw memory + long-term pointer/state token。	長期 occlusion/re-entry ヘスケール。SAM2Long/SAMURAI++ との比較。
Phase 5: Dynamic motion scan	C 案。soft directional mixture → deformable/dynamic scan。	新規性を最大化。Phase 2 の効果確認後に進む。

もし研究期間上、1 本の主軸に絞るなら、まず Phase 1 で decoder 側の適性を 2-3 週間程度の実験単位で判定し、並行して E 案の最小 prototype (pointer sequence → causal Mamba → state token) を作るのが合理的である。A が効いても generic 性が高いため、最終主張は B または E まで進める。E が有効なら F へ伸ばすことで、SAMURAI/SAM2 の長期 memory 弱点に直接答えられる。

15. Sources / References

- R1. Gu, A.; Dao, T. “Mamba: Linear-Time Sequence Modeling with Selective State Spaces.” arXiv, 2023. <https://arxiv.org/abs/2312.00752>
- R2. Dao, T.; Gu, A. “Transformers are SSMs: Generalized Models and Efficient Algorithms Through Structured State Space Duality.” ICML, 2024. <https://proceedings.mlr.press/v235/dao24a.html>
- R3. Zhu, L. et al. “Vision Mamba: Efficient Visual Representation Learning with Bidirectional State Space Model.” ICML, 2024. <https://proceedings.mlr.press/v235/zhu24f.html>
- R4. Liu, Y. et al. “VMamba: Visual State Space Model.” NeurIPS, 2024. https://proceedings.neurips.cc/paper_files/paper/2024/hash/baa2da9ae4bfed26520bb61d259a3653-Abstract-Conference.html

- R5. Huang, T. et al. "LocalMamba: Visual State Space Model with Windowed Selective Scan." ECCV 2024 Workshops.
https://link.springer.com/chapter/10.1007/978-3-031-91979-4_2
- R6. Dang, T. D. Q. et al. "LoG-VMamba: Local-Global Vision Mamba for Medical Image Segmentation." ACCV, 2024.
https://openaccess.thecvf.com/content/ACCV2024/html/Dang_LoG-VMamba_Local-Global_Vision_Mamba_for_Medical_Image_Segmentation_ACCV_2024_paper.html
- R7. Xie, F. et al. "QuadMamba: Learning Quadtree-based Selective Scan for Visual State Space Model." NeurIPS, 2024.
https://proceedings.neurips.cc/paper_files/paper/2024/hash/d592bfaedf2f0861d7084ccea208d18-Abstract-Conference.html
- R8. Shi, Y. et al. "VSSD: Vision Mamba with Non-Causal State Space Duality." ICCV, 2025.
https://openaccess.thecvf.com/content/ICCV2025/html/Shi_VSSD_Vision_Mamba_with_Non-Causal_State_Space_Duality_ICCV_2025_paper.html
- R9. Hatamizadeh, A.; Kautz, J. "MambaVision: A Hybrid Mamba-Transformer Vision Backbone." CVPR, 2025.
https://openaccess.thecvf.com/content/CVPR2025/html/Hatamizadeh_MambaVision_A_Hybrid_Mamba-Transformer_Vision_Backbone_CVPR_2025_paper.html
- R10. Yu, W.; Wang, X. "MambaOut: Do We Really Need Mamba for Vision?" CVPR, 2025.
https://openaccess.thecvf.com/content/CVPR2025/html/Yu_MambaOut_Do_We_Really_Need_Mamba_for_Vision_CVPR_2025_paper.html
- R11. Liu, L. et al. "DefMamba: Deformable Visual State Space Model." CVPR, 2025.
https://openaccess.thecvf.com/content/CVPR2025/html/Liu_DefMamba_Deformable_Visual_State_Space_Model_CVPR_2025_paper.html
- R12. Xie, F. et al. "PVMamba: Parallelizing Vision Mamba via Dynamic State Aggregation." ICCV, 2025.
https://openaccess.thecvf.com/content/ICCV2025/html/Xie_PVMamba_Parallelizing_Vision_Mamba_via_Dynamic_State_Aggregation_ICCV_2025_paper.html
- R13. Li, T. et al. "DAMamba: Vision State Space Model with Dynamic Adaptive Scan." NeurIPS, 2025.
https://proceedings.neurips.cc/paper_files/paper/2025/hash/38b23e2328096520e9c889ae03e372c9-Abstract-Conference.html
- R14. Shi, Y. et al. "Multi-Scale VMamba: Hierarchy in Hierarchy Visual State Space Model." NeurIPS, 2024.
https://proceedings.neurips.cc/paper_files/paper/2024/hash/2d69e771d9f274f7c624198ea74f5b98-Abstract.html
- R15. Xing, Z. et al. "SegMamba: Long-range Sequential Modeling Mamba for 3D Medical Image Segmentation." MICCAI, 2024.
<https://papers.miccai.org/miccai-2024/676-Paper0663.html>
- R16. Zhu, E. et al. "UNetMamba: An Efficient UNet-Like Mamba for Semantic Segmentation of High-Resolution Remote Sensing Images." arXiv 2024 / IEEE GRSL. <https://arxiv.org/abs/2408.11545>
- R17. Wang, L. et al. "PyramidMamba: Rethinking pyramid feature fusion with selective space state model for semantic segmentation of remote sensing imagery." Int. J. Applied Earth Observation and Geoinformation, 2025.
<https://www.sciencedirect.com/science/article/pii/S156984322500531X>
- R18. "GLMambaNet: Mamba-based decoder with local detail enhancement for semantic segmentation of remote sensing imagery." Image and Vision Computing, 2025. <https://www.sciencedirect.com/science/article/abs/pii/S0262885625003622>
- R19. Zhang, X.; Tan, R. T. "Mamba as a Bridge: Where Vision Foundation Models Meet Vision Language Models for Domain-Generalized Semantic Segmentation." CVPR, 2025.
https://openaccess.thecvf.com/content/CVPR2025/html/Zhang_Mamba_as_a_Bridge_Where_Vision_Foundation_Models_Meet_Vision_CVPR_2025_paper.html
- R20. Dutta, T. K. et al. "SAM-Mamba: Mamba Guided SAM Architecture for Generalized Zero-Shot Polyp Segmentation." WACV, 2025.
https://openaccess.thecvf.com/content/WACV2025/html/Dutta_SAM-Mamba_Mamba_Guided_SAM_Architecture_for_Generalized_Zero-Shot_Polyp_Segmentation_WACV_2025_paper.html
- R21. Liang, P. et al. "MambaSAM: A Visual Mamba-Adapted SAM Framework for Medical Image Segmentation." IEEE JBHI, 2025.
<https://pubmed.ncbi.nlm.nih.gov/40031635/>
- R22. Huo, G. et al. "SAMba-UNet: Synergizing SAM2 and Mamba in UNet with Heterogeneous Aggregation for Cardiac MRI Segmentation." arXiv, 2025. <https://arxiv.org/abs/2505.16304>
- R23. Li, Y. et al. "SAM-Mamba: A Two-Stage Change Detection Network Combining the Adapting Segment Anything and Mamba Models." IEEE JSTARS, 2025. DOI 10.1109/JSTARS.2025.3601739. <https://doi.org/10.1109/JSTARS.2025.3601739>
- R24. Liu, H. et al. "ReSurgSAM2: Referring Segment Anything in Surgical Video via Credible Long-term Tracking." MICCAI, 2025.
<https://papers.miccai.org/miccai-2025/0774-Paper0617.html>
- R25. Li, X. et al. "MambaLCT: Boosting Tracking via Long-term Context State Space Model." AAAI, 2025.
<https://ojs.aaai.org/index.php/AAAI/article/view/32528>
- R26. Liu, X. et al. "MambaVLT: Time-Evolving Multimodal State Space Model for Vision-Language Tracking." CVPR, 2025.
https://openaccess.thecvf.com/content/CVPR2025/html/Liu_MambaVLT_Time-Evolving_Multimodal_State_Space_Model_for_Vision-Language_Tracking_CVPR_2025_paper.html

- R27. Ma, Y. et al. "SMTrack: State-Aware Mamba for Efficient Temporal Modeling in Visual Tracking." IEEE TIP, 2026.
<https://pubmed.ncbi.nlm.nih.gov/41729667/>
- R28. Ma, J. et al. "MADiff: Motion-Aware Mamba Diffusion Models for Hand Trajectory Prediction on Egocentric Videos." IEEE TPAMI (online 2025; issue 2026). <https://doi.org/10.1109/TPAMI.2025.3633453>
- R29. Huang, H.-W. et al. "MambaMOT: State-Space Model as Motion Predictor for Multi-Object Tracking." ICASSP, 2025.
<https://doi.org/10.1109/ICASSP49660.2025.10890199>
- R30. Ding, S. et al. "SAM2Long: Enhancing SAM 2 for Long Video Segmentation with a Training-Free Memory Tree." ICCV, 2025.
https://openaccess.thecvf.com/content/ICCV2025/html/Ding_SAM2Long_Enhancing_SAM_2_for_Long_Video_Segmentation_with_a_ICCV_2025_paper.html
- R31. Zhang, J. et al. "Efficient-SAM2: Accelerating SAM2 with Object-Aware Visual Encoding and Memory Retrieval." ICLR, 2026.
https://proceedings.iclr.cc/paper_files/paper/2026/hash/aaa0ac4253da75fa9b0dc0dda062612-Abstract-Conference.html
- R32. Xu, J. et al. "SAM4D: Segment Anything in Camera and LiDAR Streams." ICCV, 2025.
https://openaccess.thecvf.com/content/ICCV2025/html/Xu_SAM4D_SegmentAnything_in_Camera_and_LiDAR_Streams_ICCV_2025_paper.html
- R33. Yang, C.-Y. et al. "Extending Segment Anything Model 2 to Multi-Object Tracking by Optimizing Hierarchical Trajectory Memory (SAMURAI++)." CVPR Findings, 2026.
https://openaccess.thecvf.com/content/CVPR2026F/html/Yang_Extending_SegmentAnything_Model_2_to_Multi-Object_Tracking_by_Optimizing_CVPRF_2026_paper.html
- R34. Qi, Q. et al. "When Transformers Meet Mamba: A Hybrid Transformer-Mamba Network for Video Object Detection." CVPR, 2026.
https://openaccess.thecvf.com/content/CVPR2026/html/Qi_When_Transformers_Meet_Mamba_A_Hybrid_Transformer-Mamba_Network_for_Video_CVPR_2026_paper.html
- R35. Sinha, A. et al. "MS-Temba: Multi-Scale Temporal Mamba for Understanding Long Untrimmed Videos." CVPR, 2026.
https://openaccess.thecvf.com/content/CVPR2026/html/Sinha_MS-Temba_Multi-Scale_Temporal_Mamba_for_Understanding_Long_Untrimmed_Videos_CVPR_2026_paper.html
- R36. Zhu, K. et al. "RS-SSM: Refining Forgotten Specifics in State Space Model for Video Semantic Segmentation." CVPR, 2026.
https://openaccess.thecvf.com/content/CVPR2026/html/Zhu_RS-SSM_Refining_Forgotten_Specifics_in_State_Space_Model_for_Video_CVPR_2026_paper.html
- R37. Ravi, N. et al. "SAM 2: Segment Anything in Images and Videos." ICLR, 2025.
https://proceedings.iclr.cc/paper_files/paper/2025/hash/45c1f6a8cbf2da59ebf2c802b4f742cd-Abstract-Conference.html
- R38. Meta FAIR SAM2 official code: Two-Way Transformer implementation.
<https://github.com/facebookresearch/sam2/blob/main/sam2/modeling/sam/transformer.py>
- R39. Meta FAIR SAM2 official code: Memory Attention implementation.
https://github.com/facebookresearch/sam2/blob/main/sam2/modeling/memory_attention.py
- R40. Meta FAIR SAM2 official code: Memory Encoder implementation.
https://github.com/facebookresearch/sam2/blob/main/sam2/modeling/memory_encoder.py
- R41. Meta FAIR SAM2 official config (SAM2/SAM2.1 Hiera variants): memory sizes, pointers, decoder settings.
<https://github.com/facebookresearch/sam2/tree/main/sam2/configs>
- R42. Yang, C.-Y. et al. "SAMURAI: Motion-Aware Memory for Training-Free Visual Object Tracking With SAM 2." IEEE TIP, 2026.
<https://pubmed.ncbi.nlm.nih.gov/41528905/>
- R43. SAMURAI official repository. <https://github.com/yangchris11/samurai>
- R44. Liang, L. et al. "M2-SAM2: Rethinking SAM2 with Mamba-MoE for Referring Video Object Segmentation." IEEE TCSVT, 2026. DOI 10.1109/TCSVT.2026.3710580. <https://doi.org/10.1109/TCSVT.2026.3710580>
- R45. Wu, H. et al. "Bridging the Perception-Cognition Gap: Re-engineering SAM2 with Hilbert-Mamba for Robust VLM-based Medical Diagnosis." arXiv, 2025. <https://arxiv.org/abs/2512.24013>
- R46. An, J.; Grauman, K. "HieraMamba: Video Temporal Grounding via Hierarchical Anchor-Mamba Pooling." CVPR, 2026.
https://openaccess.thecvf.com/content/CVPR2026/html/An_HieraMamba_Video_Temporal_Grounding_via_Hierarchical_Anchor-Mamba_Pooling_CVPR_2026_paper.html
- R47. Chen, Y. et al. "Efficient Plug-and-Play Mamba-based Selective Target State Modeling for Lightweight Visual Tracking (TSTrack)." IEEE TMM, 2026. DOI 10.1109/TMM.2026.3678806. <https://doi.org/10.1109/TMM.2026.3678806>

16. 最終 Recommendation

研究として最も合理的なのは、「SAM2 の Attention を Mamba で置換する」のではなく、「SAM2 の prompt/memory 構造の中で、Attention が得意な content-addressed matching と、Mamba が得意な long-sequence selective state propagation を分業させる」ことである。Mask Decoder を主軸に進めるなら B 案、Mamba の技術的必

然性と新規性を最大化するなら E→F 案を推奨する。SAMURAI を利用できる強みは、previous mask / Kalman motion / quality という既存 SAM2 にはない target prior を、scan・routing・state update へ直接使える点にある。ここまで踏み込めば、TrackSSM/MambaMOT の trajectory predictor とも、generic SAM2+Mamba decoder とも異なる研究軸を形成できる。